



UNIVERSIDAD NACIONAL DEL ALTIPLANO

ESCUELA DE POSGRADO

MAESTRÍA EN INGENIERÍA DE SISTEMAS



TESIS

IDENTIFICACIÓN DE PROBABILIDAD DE DEFAULT DE CRÉDITOS POST IMPACTO COVID-19 EN EL SECTOR FINANCIERO PERUANO MEDIANTE TÉCNICAS DE MACHINE LEARNING

PRESENTADA POR:

MARCO ANTONIO CHUCUYA TIJUTANI

PARA OPTAR EL GRADO ACADÉMICO DE:

MAGÍSTER SCIENTIAE EN INGENIERÍA DE SISTEMAS

PUNO, PERÚ

2024



MARCO ANTONIO CHUCUYA TIJUTANI

IDENTIFICACIÓN DE PROBABILIDAD DE DEFAULT DE CRÉDITOS POST IMPACTO COVID-19 EN EL SECTOR FINANCI...

 23.- INGENIERÍA DE SISTEMAS
 23.- INGENIERÍA DE SISTEMAS
 Universidad Nacional del Altiplano

Detalles del documento

Identificador de la entrega

trn:oid::8254:438284089

107 Páginas

Fecha de entrega

10 mar 2025, 6:36 p.m. GMT-5

22,171 Palabras

Fecha de descarga

10 mar 2025, 9:41 p.m. GMT-5

119,848 Caracteres

Nombre de archivo

IDENTIFICACIÓN DE PROBABILIDAD DE DEFAULT DE CRÉDITOS POST IMPACTO COVID-19 EN ELdocx

Tamaño de archivo

2.8 MB



M.Sc. Pedro Feder Ponce Cordero
INGENIERO DE SISTEMAS
CIP. 116757





16% Similitud general

El total combinado de todas las coincidencias, incluidas las fuentes superpuestas, para ca...

Filtrado desde el informe

- Bibliografía
- Texto citado
- Texto mencionado
- Coincidencias menores (menos de 12 palabras)

Fuentes principales

- 14%  Fuentes de Internet
- 1%  Publicaciones
- 7%  Trabajos entregados (trabajos del estudiante)

Marcas de integridad

N.º de alertas de integridad para revisión

No se han detectado manipulaciones de texto sospechosas.

Los algoritmos de nuestro sistema analizan un documento en profundidad para buscar inconsistencias que permitirían distinguirlo de una entrega normal. Si advertimos algo extraño, lo marcamos como una alerta para que pueda revisarlo.

Una marca de alerta no es necesariamente un indicador de problemas. Sin embargo, recomendamos que preste atención y la revise.


 M.Sc. Pedro Feder Ponce Cordero
INGENIERO DE SISTEMAS
CIP: 116757


 Ingeniero Jared Luque Coya
ING. ESTADISTICO E INFORMATICO
CIP: 116625





UNIVERSIDAD NACIONAL DEL ALTIPLANO

ESCUELA DE POSGRADO

MAESTRÍA EN INGENIERÍA DE SISTEMAS

TESIS

IDENTIFICACIÓN DE PROBABILIDAD DE DEFAULT DE CRÉDITOS POST IMPACTO COVID-19 EN EL SECTOR FINANCIERO PERUANO MEDIANTE TÉCNICAS DE MACHINE LEARNING



PRESENTADA POR:

MARCO ANTONIO CHUCUYA TIJUTANI

PARA OPTAR EL GRADO ACADÉMICO DE:

MAGÍSTER SCIENTIAE EN INGENIERÍA DE SISTEMAS

APROBADA POR EL JURADO SIGUIENTE:

PRESIDENTE

.....
D.Sc. ADOLFO CARLOS JIMENEZ CHURA

PRIMER MIEMBRO

.....
D.Sc. DONIA ALIZANDRA RUELAS ACERO

SEGUNDO MIEMBRO

.....
Mtro. ALDO HERNAN ZANABRIA GALVEZ

ASESOR DE TESIS

.....
M.Sc. PEDRO FEDER PONCE CORDERO

Puno, 26 de diciembre de 2024.

ÁREA: Ingeniería de Software, Base de datos e Inteligencia Artificial.

TEMA: Probabilidad de default de créditos post impacto COVID-19 en el sector financiero.

LÍNEA: Sistemas, Computación e Informática



DEDICATORIA

Con mucho cariño para mi familia:

Mis hijos Piero Antonio y Amira Victoria,

Mi esposa Zhenia Jackelin Ramos Apaza.

Mi madre Candelaria Tijutani Alanguia (Q.E.P.D)

Mi Padre Antonio Seul Chucuya Zaga

Marco Antonio Chucuya Tijutani.



AGRADECIMIENTOS

A la Universidad Nacional del Altiplano, al Escuela de Post Grado y el programa de Maestría en Ingeniería de Sistemas.

A los miembros del Jurado:

Dr. Adolfo C. Jimenez Chura, Dra. Donia A. Ruelas Acero, Dr. Aldo Zanabria Galvez.

Y a mi asesor: Mg. Pedro Feder Ponce Cordero; por sus recomendaciones y sugerencias durante el desarrollo de la investigación.

Marco Antonio Chucuya Tijutani.

ÍNDICE GENERAL

	Pág.
DEDICATORIA	i
AGRADECIMIENTOS	ii
ÍNDICE GENERAL	iii
ÍNDICE DE TABLAS	v
ÍNDICE DE FIGURAS	vi
ÍNDICE DE ANEXOS	vii
ACRÓNIMOS	viii
RESUMEN	1
ABSTRACT	2
INTRODUCCIÓN	3

CAPÍTULO I

REVISIÓN DE LITERATURA

1.1	Marco teórico	5
1.1.1	Probabilidad Default	5
1.1.2	Situación de Créditos	5
1.1.3	Créditos Ex Ante	5
1.1.4	Créditos Ex Post	6
1.1.5	Machine Learning	8
1.1.6	Logistic Regression	14
1.1.7	Support Vector Machines	16
1.1.8	RandomForest	19
1.1.9	XGBoost	20
1.1.10	LightGBM	21
1.1.11	Redes Neuronales Artificiales (ANN)	24
1.2	Antecedentes	28
1.2.1	Internacionales	28
1.2.2	Nacionales	36
1.2.3	Locales	36

CAPÍTULO II

PLANTEAMIENTO DEL PROBLEMA

2.1	Identificación del problema	37
-----	-----------------------------	----



2.2	Enunciados del problema	38
2.2.1	Problema general	38
2.2.2	Problemas específicos	38
2.3	Justificación	39
2.4	Objetivos	40
2.4.1	Objetivo general	40
2.4.2	Objetivos específicos	40
2.5	Hipótesis	40
2.5.1	Hipótesis general	40
2.5.2	Hipótesis específicas	41

CAPÍTULO III

MATERIALES Y MÉTODOS

3.1	Lugar de estudio	42
3.2	Población	42
3.3	Muestra	42
3.4	Método de investigación	42
3.5	Descripción detallada de métodos por objetivos específicos	42
3.5.1	Diagnóstico	43
3.5.2	Evaluación	43
3.5.3	Implementación	44

CAPÍTULO IV

RESULTADOS Y DISCUSIÓN

4.1	Resultados	47
4.1.1	Resultado conforme al primer objetivo	47
4.1.2	Resultado de acuerdo al segundo objetivo específico	56
4.1.3	Análisis comparativo de modelos de Machine Learning	66
4.2	Discusión	68
4.2.1	Prueba de Hipótesis	69

CONCLUSIONES	74
--------------	----

RECOMENDACIONES	75
-----------------	----

BIBLIOGRAFÍA	76
--------------	----

ANEXOS	82
--------	----

ÍNDICE DE TABLAS

	Pág.
1. Métricas empleadas para evaluación de modelos de Machine Learning	44
2. Modelos empleados en investigaciones antecedentes	45
3. Campos de información antes del desembolso de crédito	48
4. Información de campos posterior al desembolso	50
5. Información de campos calculados posterior al desembolso	52
6. Variables para el entrenamiento	54
7. Métricas resultantes a nivel multiclase del entrenamiento con RL	57
8. Métricas ponderadas resultantes del entrenamiento de Regresión Logística	58
9. Métricas resultantes a nivel multiclase del entrenamiento de Random Forest	59
10. Métricas ponderadas resultantes del entrenamiento con Random Forest	60
11. Métricas resultantes a nivel multiclase del entrenamiento con SVM	60
12. Métricas ponderadas resultantes el entrenamiento con SVM	61
13. Métricas resultante a nivel multiclase del entrenamiento con ANN	62
14. Métricas ponderadas del entrenamiento con ANN	63
15. Métricas a nivel multiclase resultantes del entrenaminto con LightGBM	63
16. Métricas ponderadas resultantes del entrenamiento con LightGBM	64
17. Métricas resultantes a nivel multiclase del entrenamiento con XGBoost	64
18. Métricas ponderadas resultantes del entrenamiento con XGBoost	65
19. Comparativa de métricas resultantes por modelo	66
20. Prueba estadística de hipótesis para Regresion Logística	69
21. Prueba estadística de hipótesis para Support Vector Machines	70
22. Prueba estadística de hipótesis para Artificial Neural Networks	71
23. Prueba estadística de hipótesis para Light Gradient Boost Machines	72
24. Prueba estadística de hipótesis para Extreme Gradient Boost	73

ÍNDICE DE FIGURAS

	Pág.
1. Perceptrón simple	13
2. Hiperplano de un SVM	16
3. Hiperplano optimo de una SVM	17
4. Tolerancia a fallos en el hiperplano de SVM	19
5. Esquema neuronal de una capa en ANN	28
6. Modelo One-hot para el preprocesado	44
7. Entrenamiento de modelos de Machine Learning para la investigación	46
8. Flujo de información en el proceso de otorgamiento	47
9. Esquema de transición de información de Ex Ante a Ex Post	48
10. Comportamiento ejemplo de un crédito con respecto al umbral	53
11. Comparación de métricas de los modelos de Machine Learning	67



ÍNDICE DE ANEXOS

	Pág.
1. Matriz de consistencia	82
2. Seguimiento de colocaciones	83
3. Curva AUC ROC de Regresión Logística.	84
4. Matriz de confusión de Regresión Logística	85
5. Curva AUC ROC de Random Forest	86
6. Matriz de confusión de Random Forest	87
7. Curva AUC ROC de Support Vector Machines	88
8. Matriz de confusión de Support Vector Machines	89
9. Curva AUC ROC de Artificial Neural Networks	90
10. Matriz de Confusión de Artificial Neural Networks	91
11. Curva AUC ROC de Extreme Gradient Boost	92
12. Matriz de Confusión de Extreme Gradient Boost	93
13. Declaración jurada de autenticidad de tesis	94
14. Autorización para el depósito repositorio institucional	95



ACRÓNIMOS

ANN	: Artificial Neural Networks
AUC	: Area Under the Curve
GBTD	: Gradient Boost Tree Desicion
INEI	: Instituto Nacional de Estadística e Informática
LGBM	: Light Gradient Boost Machines
MEF	: Ministerio de Economía y Finanzas
NIIF	: Normas Internacionales de Información Financiera
PD	: Probabilidad default
PDM	: Probabilidad default al mes M
RCC	: Registro Consolidado de Créditos
RF	: Random Forest
RL	: Regresión Logística
ROC	: Receiver Operating Characteristic
SBS	: Super intendencia de Banca y Seguros.
SVM	: Support Vector Machines
XGB	: Extreme Gradient Boost
XGBOOST	: Extreme Gradient Boost

RESUMEN

Uno de los principales problemas y retos de la banca en el sector financiero es identificar al crédito con mayor probabilidad de incurrir al impago y de esta manera estimar la pérdida, es decir la probabilidad default (PD). La información base para la presente investigación es del sector financiero peruano. En el presente estudio se pretende identificar el modelo de aprendizaje automático con mayor rendimiento para identificar la PD de una operación crediticia con afectaciones en comportamiento de pago por el impacto de la COVID-19. La información es obtenida de un repositorio con datos históricos de varios periodos, concentrada por la Super Intendencia de Banca y Seguros del Perú, y la población son 1.2 millones de registros, donde el 80 % será para entrenamiento y el 20 % para pruebas. La investigación es de tipo no experimental con el enfoque cuantitativo y la evaluación estará realizada mediante la curva ROC y la matriz de confusión. Los modelos a evaluar son Regresion Logistica, Random Forest, Support Vector Machines, ANN, Extreme Gradient Boost y Light Gradient Boost y las métricas para evaluación serán precision, accuracy, recall y F1-score. En los resultados obtenidos el modelo con mayor comportamiento para la predicción es el modelo Extreme Gradient Boost, con un accuracy del 91 % y el mismo valor para precision, recall y F1-score. En conclusión, el modelo más asertivo para la predicción de la identificación de la PD de un crédito post impacto COVID-19 es Extreme Gradient Boost seguido de cerca por Random Forest.

Palabras clave: Crisis COVID-19, Machine Learning, Micro financiero, Probabilidad default, Riesgo Crediticio.

ABSTRACT

One of the main problems and challenges of banking in the financial sector is to identify the credit with the greatest probability of defaulting and in this way estimate the loss, that is the Probability of Default (PD). The base information for this research comes from the peruvian financial sector. This study aims to identify the machine learning model with the best performance to identify the PD of a credit operation with effects on its payment behavior due to the impact of COVID-19. The information is obtained from a repository containing historical data across various periods, concentrated by the Superintendence of Banking and Insurance of Peru, and the population is 1.2 million records, where 80 % will be allocated for training and 20 % for testing. The research is non-experimental with a quantitative approach and the evaluation will be conducted using the ROC curve and the confusion matrix. The models to be assessed are Logistic Regression, Random Forest, Support Vector Machines, Artificial Neural Networks (ANN), Extreme Gradient Boost and Light Gradient Boost and the metrics for evaluation will be precision, accuracy, recall, and F1-score. The results show that the model with the best performance for prediction is Extreme Gradient Boost, achieving an accuracy of 91 %, with the same value for precision, recall, and F1-score. In conclusion, the most effective model for predicting and identifying the PD of a credit post COVID-19 impact is Extreme Gradient Boost, followed closely by Random Forest.

Keywords: COVID-19 Crisis, Credit Risk, Default probability, Machine Learning, Micro financial.

V°B°

Firmado digitalmente por
PACHECO TANAKA Myrian
Eugenia FAU 20145496170 soft
Motivo: Doy V° B°
Fecha: 06.03.2025 16:57:39 -05:00

INTRODUCCIÓN

La pandemia de COVID-19 marcó uno de los choques económicos más disruptivos de la historia moderna, alterando los fundamentos económicos y financieros de manera significativa. En el sistema financiero, estas disrupciones se tradujeron en un aumento abrupto de los riesgos crediticios, una presión sin precedentes sobre la solvencia de las instituciones financieras, y un incremento generalizado en las probabilidades de incumplimiento (PD) de empresas, hogares y entidades soberanas. El análisis de estos eventos es fundamental para entender cómo los sistemas financieros absorben y se adaptan a shocks sistémicos, y cómo las políticas económicas pueden contribuir a estabilizarlos y prevenir crisis futuras.

La probabilidad de default (PD) es una métrica esencial en la evaluación del riesgo crediticio. Mide la probabilidad de que un prestatario incumpla sus obligaciones dentro de un horizonte temporal específico, y constituye un componente crítico en la gestión del riesgo en bancos y otras instituciones financieras (Altman et al., 2022). Durante la pandemia, múltiples factores contribuyeron a elevar la PD, incluyendo la contracción económica global, la volatilidad de los mercados financieros, y la interrupción de cadenas de suministro. Además, las medidas de estímulo fiscal y monetario, aunque necesarias, introdujeron dinámicas adicionales, como el aumento en los niveles de deuda y riesgos asociados a una eventual normalización de tasas de interés (IMF, 2020).

El objetivo principal de esta investigación es determinar el mejor modelo de *Machine learning* para identificar la probabilidad default de un crédito con comportamiento afectado por la pandemia dada por el fenómeno denominado COVID-19. Para el cual se tuvo que estudiar y analizar las variables del flujo de información provenientes de las bases de datos crediticios de una entidad financiera. Posterior a ello se obtuvo el set de datos definitivo; seguidamente se preproceso la información para el entrenamiento de diferentes modelos de *machine learning*. Los resultados serian evaluados de las métricas de *Accuracy*, *Precision*, *F1-Score*, y *AUC ROC* en los cuales bajo la observación se determinaría la asertividad de cada modelo.

La presente investigación está estructurada en cuatro capítulos. En el capítulo I se presenta la revisión de la bibliografía dentro del marco teórico, además de los antecedentes de la investigación. En el capítulo II se presenta la identificación y seguido de la formulación del problema, así como la justificación de la misma finalizando con los



objetivos de la investigación. En el capítulo III se presenta los materiales y métodos empleados en la investigación, se agrega en este apartado también la población y muestra en el capítulo IV se presentan los resultados generados y finalmente se expone las conclusiones y recomendaciones inherentes de la investigación.

CAPÍTULO I

REVISIÓN DE LITERATURA

1.1 Marco teórico

1.1.1 Probabilidad Default

La probabilidad de default se refiere a la probabilidad de que la contraparte no pueda cumplir con sus obligaciones en un plazo temporal determinado. Es un parámetro principal en el método de modelos internos basados en clasificaciones internas (Internal Rating-Based). Este modelo permite a las entidades del sector financiero calcular la pérdida esperada de manera que puedan mitigar el riesgo de crédito al requerir capital para el mismo. La utilización de este método de manera regulatoria se acordó en la cumbre de Basilea en el denominado Acuerdo de Basilea II donde establece que uno de los 3 principales pilares es el requerimiento de capital para mitigar el riesgo de crédito (SBS, 2006).

1.1.2 Situación de Créditos

En el contexto de la economía, las finanzas y la política pública, los términos créditos ex ante y créditos ex post se utilizan para describir dos enfoques diferentes en la asignación y el uso de recursos financieros, particularmente en relación con proyectos o políticas que requieren financiamiento. Ambos conceptos están relacionados con los momentos en que se otorgan o se gestionan los créditos, diferenciándose por el período de tiempo en el que se accede al financiamiento y el riesgo asociado. El entendimiento de estas dos modalidades es esencial para la gestión financiera en áreas como la planificación de inversiones públicas, los seguros, las políticas de desarrollo económico y las estrategias de mitigación de riesgos (Martínez Heras, 2023).

1.1.3 Créditos Ex Ante

Los créditos ex ante son aquellos que se conceden antes de la realización de la operación de desembolso. En este contexto, “ex ante” se traduce como “antes de”, lo que implica que el financiamiento se otorga para cubrir los costos previstos o para financiar las actividades que se llevarán a cabo. El propósito de los créditos ex ante es proporcionar los recursos necesarios antes de que el evento o proyecto

se ejecute, permitiendo una planificación financiera previa y asegurando la disponibilidad de fondos para cumplir con los objetivos.

En términos de política pública, los créditos ex ante se usan para financiar proyectos de inversión o políticas que están en fase de preparación o planificación. Estos fondos se asignan basándose en estimaciones o proyecciones de costos y beneficios, y la idea es reducir la incertidumbre financiera antes de la ejecución de las actividades. En general, se espera que los proyectos financiados con créditos ex ante sean bien definidos y planificados, ya que el financiamiento se basa en expectativas y no en resultados verificables (Keynes, 2017).

Ejemplos de créditos ex ante:

Préstamos para proyectos de infraestructura: Los gobiernos o las instituciones financieras pueden otorgar créditos para la construcción de carreteras, hospitales o escuelas antes de que se inicie el trabajo de construcción.

Subsidios para investigación y desarrollo: Empresas o instituciones pueden recibir financiamiento para actividades de investigación antes de conocer los resultados, basándose en los objetivos del proyecto.

1.1.4 Créditos Ex Post

En contraste, los créditos ex post son aquellos que se han otorgado mediante la operación de desembolso. El término “ex post” se traduce como “después de”, indicando que el financiamiento se concede una vez que se ha obtenido la información sobre los costos reales, los resultados alcanzados o el impacto de la actividad. Estos créditos se utilizan generalmente en situaciones en las que ya se ha ejecutado una inversión o actividad y se requiere financiamiento para cubrir gastos adicionales, pérdidas inesperadas o para implementar medidas de compensación.

Los créditos ex post permiten una mayor flexibilidad en la gestión financiera, ya que se basan en hechos y resultados concretos, lo que puede reducir el riesgo de asignar recursos sin una evaluación completa de los resultados. En algunos casos, los créditos ex post también son utilizados para financiar compensaciones o indemnizaciones, como en el caso de seguros o fondos de contingencia ante desastres naturales o crisis económicas (Secretaría de Hacienda y Crédito Público, 2015).

Ejemplos de créditos ex post:

Reembolsos por daños tras desastres naturales: Después de un huracán o terremoto, los gobiernos o instituciones pueden ofrecer créditos o fondos para cubrir los costos de recuperación y reconstrucción.

Fondeo de programas de emergencia: En situaciones donde los costos no fueron previstos o sobrepasaron las expectativas, los créditos ex post pueden utilizarse para cubrir los gastos adicionales.

A. Diferencias Clave entre Créditos Ex Ante y Ex Post

A.1 Tiempo de Asignación

Los créditos ex ante se asignan antes del desembolso. Los créditos ex post se otorgan después del desembolso.

A.2 Riesgo y Certidumbre

Los créditos ex ante implican una mayor incertidumbre, ya que se basan en proyecciones y estimaciones futuras. Los créditos ex post, por su parte, suelen tener un menor riesgo, ya que se asignan con base en resultados tangibles y verificables.

A.3 Finalidad

Los créditos ex ante están orientados a financiar actividades y proyectos futuros. Los créditos ex post están diseñados para abordar situaciones imprevistas o para compensar sobre costos o pérdidas.

A.4 Gestión y Planificación

Los créditos ex ante requieren una planificación y evaluación detallada antes de la ejecución. Los créditos ex post ofrecen más flexibilidad en la gestión, pero dependen de los resultados alcanzados.

B. Aplicaciones y Relevancia

Ambos tipos de créditos tienen un papel esencial en diversas áreas de la economía y la gestión pública. Por ejemplo, los créditos ex ante son comunes en la financiación de proyectos a largo plazo, como la construcción de infraestructura o el lanzamiento de nuevos programas de

políticas públicas. En cambio, los créditos ex post son fundamentales en el contexto de la gestión de riesgos, la recuperación ante desastres y la compensación de pérdidas imprevistas.

En el ámbito de los seguros, los créditos ex post se utilizan para cubrir siniestros después de que ocurren eventos como incendios, accidentes o enfermedades. En las finanzas públicas, los créditos ex ante pueden ayudar a los gobiernos a financiar programas de desarrollo antes de que se produzcan beneficios, mientras que los créditos ex post se emplean para ajustar el financiamiento cuando las condiciones cambian o surgen imprevistos (Escobar Rozas, 2017).

1.1.5 Machine Learning

Machine Learning, también conocido como aprendizaje automático en español, tiene muchas definiciones. Por un lado, Tom Mitchell lo define como un programa de computadora que cuando realiza determinada tarea con cierto rendimiento, entonces gana cierta experiencia que le permite aumentar el rendimiento con el que realiza dicha tarea (M. I. Jordan y Tom. M. Mitchell, 2015). Por otro lado, Arthur L. Samuel indica que es el campo de estudio en las computadoras tienen la habilidad de aprender sin haber sido explícitamente programada. *Machine Learning* se clasifica dentro del ámbito de la Inteligencia Artificial que forma parte de una de las ramas que conforman las ciencias de la computación. Hoy en día *Machine Learning* permite a cualquier persona trabajar sus datos y de esta manera alcanzar una mayor ventaja competitiva. Anteriormente, esto solo estaba al alcance de las grandes empresas y corporaciones (Power Data, 2024).

Hoy en día podemos indicar que tenemos una gran cantidad de datos, tanto estructurados como sin estructurar. Así el aprendizaje automático ha ido evolucionando en los últimos años en la rama que conocemos como inteligencia artificial de forma que podemos tener máquinas capaces de predecir gran cantidad de información basándose en la que y tiene almacenada y procesada previamente. Así tenemos muchas aplicaciones de las que podemos sacar partido del aprendizaje automático, entre ellas está la de clasificar, como puede ser por ejemplo detectar si un correo es considerado como spam o no. En 10 años el aprendizaje automático ha

conquistado la industria del día a día ayudando a los humanos a aprender de los mismos, como por ejemplo posicionamiento de una web en un motor de búsqueda, reconocimiento de voz, reconocimiento de imágenes, o algo tan sonado hoy en día como son los coches autónomos (Martínez Heras, 2023).

A. Aprendizaje supervisado

El aprendizaje supervisado generalmente comienza con un conjunto establecido de datos y una cierta comprensión de cómo se clasifican esos datos; por ejemplo, si le damos abundante información de imágenes de animales (perros y gatos), y etiquetamos cada imagen como perro o gato, entonces el sistema aprenderá a identificar un gato o un perro en otra imagen cualquiera distinta con la que fue entrenado (Hurwitz y Kirsch, 2018)

B. Aprendizaje no supervisado

El aprendizaje no supervisado es más adecuado cuando el problema requiere una gran cantidad de datos sin etiqueta; por ejemplo, le damos abundante información de imágenes de (gatos y perros), pero no le decimos al sistema que son gatos o perros, por lo que la comprensión del significado detrás de estas imágenes, requiere algoritmos que pueden comenzar a comprender el significado de las imágenes para poder clasificar los “gatos o perros” en cualquier otra imagen (Hurwitz y Kirsch, 2018).

C. Aprendizaje por reforzamiento

El aprendizaje por reforzamiento es un modelo de aprendizaje conductual, donde el algoritmo recibe retroalimentación del análisis de los datos para que el usuario sea guiado hacia el mejor resultado; es decir, se aprende con estímulos de ponderación alta si se acerca al objetivo o ponderaciones menores si comete errores (Hurwitz y Kirsch, 2018).

D. Algoritmos de Clasificación

Existen distintas categorías para estos algoritmos atendiendo al tipo de clasificación que realicen. Vamos a destacar los más usados e

importantes que podemos encontrar para resolver numerosos problemas de clasificación en los que basaremos nuestro proyecto y los que analizaremos (Chris Albon, 2018). Así podemos encontrar los siguientes dentro de estas categorías según su naturaleza:

- Linear Models: Logistic Regression, Perceptron
- Neural Network: MultiLayerPerceptron
- Discriminant Analysis: Linear Discriminant Analysis, Quadratic Discriminant Analysis
- Support Vector Machines: Linear Support Vector Machines, Polynomial Support Vector Machines
- Neighbors: Kneighbors
- NaiveBayes: BernoulliNB, GaussianNB, MultinomialNB
- Trees: DecisionTree
- Ensemble: AdaBoost, RandomForest

A continuación, vamos a proceder a explicar el funcionamiento de cada uno. El análisis del comportamiento a través de métricas de cada algoritmo nos ayudará a entender mejor cómo funciona cada uno internamente y así extraer conclusiones de los valores para llevar a cabo la comparativa. Además de los algoritmos indicados previamente existen otros que también pueden ser usados para clasificación, pero, por no ser tan relevantes o tan usados en otros sistemas, los citaremos e incluiremos sus datos, aunque no analicemos en profundidad su comportamiento (Raschka y Mirjalili, 2019).

Muchos de ellos son capaces de realizar clasificación multiclase, pero hay otros que por su naturaleza es binaria, distinción entre dos clases. Para solventar el problema donde tenemos que clasificar tres o más clases, se usan distintas estrategias para así convertirlos en clasificadores multiclase. Estas técnicas son conocidas como one-vs-one y one-vs-all o también conocida como one-vs-rest (OvR) (Chris Albon, 2018). Cada una de ellas se comporta de la siguiente forma:

- one-vs-one: Se encarga de dividir el problema de N clases en $N(N-1)/2$ subproblemas binarios. Se realizan clasificaciones entre dos clases $\{C_i, C_j\}$ donde obtendremos un grado de confianza en favor de C_i en el rango de $[0,1]$. Cada subproblema binario se almacena en una matriz de votos. Para extraer cual es la clase a la que pertenece se usa la estrategia del voto ponderado la que alcanza la mayor confianza total es la que se predice (Psaltakis et al., 2024).
- one-vs-all: Esta estrategia se basa en realizar una clasificación por cada clase que tengamos. Si tenemos 3 clases a distinguir entre nuestro conjunto de datos entonces realizaremos 3 clasificaciones binarias. Así, por ejemplo, para la clasificación de la primera clase, vamos a considerar positivos todos aquellos que cumplan la función que le pasemos, y negativos todos los demás que no la cumplan, aquí estaríamos haciendo una clasificación binaria, y así haremos para todas las demás clases (Chris Albon, 2018). Supongamos que $f_i(x)$ es la clasificación i -ésima para el ejemplo x . La clasificación final para $f(x) = \arg \max_i f_i(x)$, es decir, el máximo valor de todas las clasificaciones binarias realizadas.

E. Modelos Lineales

E.1 Perceptrón

El perceptrón es un modelo de neurona simple. En 1958 el psicólogo Frank Rosenblat desarrolló este modelo basado en el de McCulloch y Pitts (1943) y en una regla de aprendizaje basada en la corrección del error, a este modelo le llamó Perceptrón. Lo que más llamó la atención en este modelo es su capacidad para aprender a reconocer patrones. El perceptrón se basa en una serie de sensores o entradas desde donde recibe los datos a clasificar o reconocer y donde tenemos además una neurona de salida para indicarnos si pertenece a una clase u otra, activándose o no dependiendo si la salida es 1 o 0 (McCulloch y Pitts, 1943).

Para explicar en qué consiste el algoritmo del perceptrón simple vamos a explicar en qué funciones se basa para llevar a cabo una clasificación de datos, basada en el concepto de:

E.2 Perceptrón simple

Vamos a comenzar suponiendo que tenemos la función f de R^n en $\{-1, 1\}$, a la que le podemos aplicar un patrón de entrada $x = (x_1, x_2, \dots, x_n)^T \in R^n$ y donde tendremos una salida deseada $z \in \{-1, 1\}$, o lo que es lo mismo, $f(x) = z$.

Ese patrón de entrada lo vamos a considerar como cada característica que tiene nuestro conjunto de datos y al que le vamos a pasar dicha función. Como tenemos un número de patrones de entrada para llevar a cabo la clasificación vamos a tener la siguiente relación:

$\{x_1, z_1\}, \{x_2, z_2\}, \dots, \{x_p, z_p\}$, donde x_i es el patrón de entrada $i \in R^n$ y $z = f(x_i)$.

La función lo que realiza es una partición del conjunto de entradas en dos espacios, por una parte, tendríamos los patrones de entrada cuya salida es $+1$ y por otro los patrones cuya salida es -1 , así podemos decir que esta función es capaz de distinguir entre dos clases. Debido a que nuestro problema trata la clasificación de más de dos clases, el perceptrón simple admite la técnica de clasificación one-vs-all debido a que las salidas que obtenemos son continuas y numéricas, técnica explicada previamente en este capítulo (Hathidara y Pandey, 2024).

¿Y cómo podemos construir un modelo que cumpla con esa función? Partiremos para

ello de una unidad de proceso bipolar que cumple la siguiente función:


$$1 \text{ si } w_1x_1 + w_2x_2 + \dots + w_nx_n \geq \theta$$

$$-1 \text{ si } w_1x_1 + w_2x_2 + \dots + w_nx_n \leq \theta$$

donde tenemos que los parámetros w_i son los llamados pesos sinápticos. Estos pesos supondrán la importancia o la ponderación que le damos a cada valor de entrada. Por otro lado, tenemos la suma ponderada que llamamos potencial sináptico y por último el umbral que es θ . Cuando la salida de dicha función es 1 se dice que está activa y en caso contrario su salida será -1 o que está inactiva (Gutiérrez, 2020).

Figura 1

Perceptrón simple



El valor inicial de los pesos sinápticos y el umbral se realiza a través de un proceso adaptativo tomando unos valores iniciales aleatorios que se irán modificando según se acerque o no a la salida deseada en el entrenamiento. La regla para la modificación de los pesos sinápticos es la conocida Regla de aprendizaje del Perceptrón Simple (Gutiérrez, 2020). Esta regla consiste en lo siguiente: $w_j(k+1) = w_j(k) + \Delta w_j(k)$, para $k = 1, 2, \dots$ y donde tenemos que

$$\Delta w_j(k) = \eta (z(k) - y(k)) x_j(k),$$

explicándolo podemos decir que, la variación del peso para w_j es proporcional al producto del error ($z(k) - y(k)$) por la componente j -ésima del patrón de entrada que hemos introducido en la iteración k , es decir, $x_j(k)$. La constante η es lo que llamamos tasa de aprendizaje e indica el valor por el que cambiaremos cada peso sináptico (Gutiérrez, 2020)

Así esta regla es de detección y corrección del error ya que aprende, o modifica los pesos, cuando existe una equivocación.

El algoritmo del perceptrón funciona de la siguiente forma:

1. Iniciamos los pesos sinápticos con valores aleatorios en el intervalo $[-1,1]$. Ir al paso 2

con $k=1$

2. Iteración k -ésima:

a. Calcular la salida $y(k)$ según la función comentada previamente

3. Corregir pesos sinápticos:

a. Si la salida de $y(k) \neq z(k)$ (la salida no es la deseada), entonces modificamos pesos aplicando la regla de aprendizaje del perceptrón simple comentada previamente.

4. Fin

a. Si los pesos sinápticos no se han modificados en las últimas p iteraciones entonces la red se ha estabilizado

b. En otro caso ir al paso 2 con $k = k+1$

El problema de este tipo de algoritmo es que solo es capaz de clasificar todos aquellos patrones que son linealmente separables. Dos conjuntos de patrones son linealmente separables si un número de ellos al aplicar la función son $\geq \theta$ y otro número de ellos $< \theta$.

Así encontraremos que el algoritmo del perceptrón no convergerá fácilmente si el conjunto de datos que estemos tratando no es separable linealmente y por lo tanto tiene sus limitaciones a pesar de su facilidad de implementación.

1.1.6 Logistic Regression

A pesar de su nombre, Regresión Logística es un modelo para clasificación, no para regresión. Este algoritmo es muy simple de implementar,

pero sin embargo es difícil que converja si los datos que estemos tratando no son separables linealmente (Martínez Heras, 2023).

En estadística, Regresión Logística es un modelo de regresión donde la variable dependiente es categórica, aquella que puede coger valores fijos o un número de valores posibles. Estas variables dependientes son aquellas clases objetivas que queremos predecir mientras que las variables independientes son las distintas características que componen nuestro conjunto de datos y que vamos a usar para entrenar nuestro modelo (Martínez Heras, 2023).

Para comprender cómo funciona este método es necesario también entender la ratio de probabilidad, que es la probabilidad con la que ocurra un evento. Esta ratio lo podemos

escribir de la siguiente forma: $p1-p$

donde p es la probabilidad para que ocurra un evento positivo, donde indicamos con qué certeza se va a producir un evento, por ejemplo si una persona comprará una casa. En una clasificación multiclase tendremos la probabilidad de que un dato pertenezca a una de las distintas posibles clases disponibles. Podemos ir más allá definiendo lo que es la función logit que es el logaritmo de las probabilidades: $\text{logit}(p) = \log p(1-p) = \log(p) - \log(1-p)$ (AWS, 2023, <https://aws.amazon.com/es/what-is/logistic-regression>). Esta función toma valores 0 y 1 para una clasificación binaria y los transforma en valores reales, los cuales se pueden usar para expresar una relación lineal entre las características del conjunto de datos y las probabilidades logísticas:

$$\text{logit}(p(y = 1|x)) = w_0x_0 + w_1x_1 + \dots + w_mx_m = \sum_{i=0}^m w_ix_i = W^tX$$

Como estamos interesados en la probabilidad de si un ejemplo pertenece o no a una clase, vamos a usar la inversa de la función logit y que podemos llamar como la función logística y en muchas ocasiones también nombrada como la función sigmoidea por una representación en forma de S:

$$\varphi(z) = \frac{1}{1 + e^{-z}}$$


Aquí podemos indicar que z es la entrada a la red y resulta de la combinación lineal de los pesos y las respectivas características de cada ejemplo, es decir, $Z = wTx = w_0 + w_1x_1 + \dots + w_mx_m$. Cada característica tendrá un peso debido a que cada una de ellas influirá más o menos para la decisión final de a qué clase pertenece (AWS, 2023). Por ejemplo, si queremos realizar una clasificación para determinar si un individuo es feliz o está triste, podemos asignarle pesos positivos a características que influyan en su estado de ánimo para ser feliz, o podemos asignar pesos negativos a aquellas características que influyan negativamente. Por lo tanto, para predecir si un ejemplo pertenece a una clase u otra solo tenemos que multiplicar cada característica con su correspondiente peso. La puntuación obtenida es conocida como logit score. Este valor lo pasaremos por la función softmax para extraer la probabilidad final (AWS, 2023).

1.1.7 Support Vector Machines

Este algoritmo, también llamado abreviadamente SVM, puede ser considerado como una ampliación del Perceptrón. Es importante saber de qué forma este algoritmo obtiene el hiperplano más óptimo para una clasificación binaria, un hiperplano que se encargará de separar aquellos ejemplos que pertenecen a una u otra clase. Para entender cómo funciona es mejor mostrarlo con un ejemplo. Supongamos que tenemos un conjunto de datos con 2 características, por su facilidad de visionado, donde podemos distinguir la existencia de 2 clases (Chris Albon, 2018). Vamos a buscar una línea que nos permita separar los dos conjuntos de datos:

Figura 2

Hiperplano de un SVM




En la anterior imagen, ¿Cuál podríamos considerar que es la que mejor nos distingue las dos clases? Podríamos decir que una línea no nos interesa si pasa muy cerca de uno de los puntos ya que va a ser más sensible y no va a generalizar correctamente. Lo que queremos conseguir es una línea lo más lejos posible de todos los puntos. La misión del algoritmo SVM se basa en encontrar el hiperplano que de la distancia mínima más grande a los puntos del conjunto de entrenamiento. Esa distancia es conocida como margen y la misión del hiperplano encontrado es de maximizarlo (Raschka y Mirjalili, 2019).

Para el ejemplo anterior, la representación del hiperplano encontrado en el algoritmo SVM quedaría de la siguiente forma:

Figura 3

Hiperplano optimo de una SVM



Para encontrar este hiperplano óptimo es necesario llevar a cabo una explicación de distintos conceptos y cómo el algoritmo llega a encontrarlo.

La fórmula que define un hiperplano es la siguiente: $f(x) = \beta_0 + \beta^T x$ donde β es el vector de pesos y β_0 son las bias. El hiperplano puede ser representado de varias formas con valores distintos en β y en β_0 (Raschka y Mirjalili, 2019). Para una mejor comprensión vamos a optar por usar $|\beta_0 + \beta^T x| = 1$ donde:

x es el vector de puntos del conjunto de entrenamiento más cercanos al hiperplano, estos son los llamados vectores de soporte o support vector. Para saber la distancia existente entre el hiperplano (β, β_0) y esos puntos (x) usaremos la geometría (Raschka y Mirjalili, 2019), donde tenemos que:

$$dist = |\beta_0 + \beta^T x| / \|\beta\|.$$

Como la ecuación del hiperplano es igual a 1, definida previamente, la ecuación de distancia nos quedaría así: $dist = 1 / ||\beta||$. Como indicamos previamente el margen que buscamos, denotado como M , es el doble de la distancia al ejemplo más cercano, ya que queremos que esté lo suficientemente separado de estos vectores de soporte (Bhatt et al., 2024), así tenemos: $M = 2 / ||\beta||$.

Finalmente, el problema de maximizar M es equivalente al problema de minimizar $L(\beta)$ sujeto a varias restricciones. Estas restricciones son las que van a modelar el requisito para que el hiperplano clasifique correctamente los ejemplos del conjunto de entrenamiento x_i (Bhatt et al., 2024).

Formalmente podemos decir:

$$\min_{\beta, \beta_0} L(\beta) = \frac{1}{2} ||\beta||^2 \text{ subject to } y_i(\beta^T x_i + \beta_0) \geq 1 \forall i$$

donde en y_i tenemos las etiquetas del conjunto de entrenamiento (Bhatt et al., 2024).


Este tipo de problema es conocido como optimización lagrangiana y que puede ser resuelto usando los multiplicadores de Lagrange para obtener el vector peso. Las restricciones modelan el requisito para que el hiperplano clasifique correctamente todos los ejemplos de entrenamiento β y las bias β_0 del hiperplano óptimo (Raschka y Mirjalili, 2019).

Pero, ¿qué ocurre si los datos con los que tratamos no son linealmente separables? Supongamos que tenemos el siguiente conjunto de datos donde queremos extraer el

hiperplano óptimo:

Figura 4

Tolerancia a fallos en el hiperplano de SVM



Para los datos que no son linealmente separables lo que hacemos es rebajar las restricciones penalizando en este caso las instancias que son clasificadas erróneamente con el parámetro de costo C y las variables de holgura ξ_i que son las que definen la cantidad de puntos que están en el lado equivocado del margen (Bhatt et al., 2024).

1.1.8 RandomForest

En este tipo de algoritmos de conjunto se realiza una búsqueda de un clasificador más preciso con el uso de árboles de decisión. Su uso lo podemos encontrar para clasificación del tipo de cobertura de tierra. Cada árbol de decisión que se crea se hace a partir de una secuencia aleatoria de un subconjunto de datos del conjunto de entrenamiento. La diferencia con un árbol de decisión es que en el nodo donde tenemos que hacer la división de los datos no se toma aquel atributo con mayor ganancia o índice gini, sino que se coge la mejor división entre un subconjunto aleatorio de todo el conjunto de características. Esto provocará una desviación mayor del árbol, pero al usar la media de varios árboles la varianza decrementa (Chris Albon, 2018).

La forma en que clasifica este algoritmo es de la siguiente forma: dado un ejemplo con sus respectivas características se sitúan en cada uno de los árboles de decisión que hay en el bosque y que el algoritmo ha creado. Cada árbol dará una clasificación y ese árbol le da una votación a esa clase que ha predicho. El bosque elige la clasificación a través de aquella clase que haya sido más votada (Chris Albon, 2018).

1.1.9 XGBoost

XGBoost (Extreme Gradient Boosting) es una librería de aprendizaje automático de alto rendimiento basada en el algoritmo de boosting, que ha demostrado ser altamente efectiva en una variedad de tareas de clasificación y regresión. Fue desarrollada por T. Chen y Guestrin en 2016 y se ha convertido en una de las herramientas más populares y efectivas para la resolución de problemas complejos en ciencia de datos (T. Chen y Guestrin, 2016). Este enfoque se basa en la mejora iterativa de modelos mediante el entrenamiento de árboles de decisión, y su eficacia en competencias de ciencia de datos, como Kaggle, ha consolidado su relevancia en la práctica.

A. Principios Fundamentales de XGBoost

El núcleo de XGBoost es el algoritmo de gradient boosting, que combina múltiples modelos débiles (árboles de decisión) para construir un modelo fuerte. A diferencia de otros enfoques, como Random Forest, XGBoost es un modelo secuencial, donde cada nuevo árbol se entrena para corregir los errores cometidos por los árboles anteriores. Este proceso es conocido como boosting, en el cual el error residual de los árboles previos se ajusta de manera iterativa (Friedman, 2001).

XGBoost mejora el algoritmo de boosting tradicional al integrar diversas optimizaciones, como el uso de regularización (tanto L1 como L2), lo que ayuda a reducir el sobreajuste (overfitting) y aumenta la capacidad de generalización del modelo (T. Chen y Guestrin, 2016).

B. Características de XGBoost

Regularización: A diferencia de otros métodos de boosting, XGBoost implementa un término de regularización en la función objetivo, lo que mejora la capacidad de generalización del modelo y controla el sobreajuste (T. Chen y Guestrin, 2016).

Paralelización: XGBoost es altamente eficiente en términos de tiempo de ejecución, debido a su capacidad para realizar cálculos en

paralelo durante el entrenamiento, lo que acelera el proceso en grandes conjuntos de datos (T. Chen y Guestrin, 2016).

Optimización basada en el segundo orden: Utiliza el segundo orden de derivadas en su algoritmo de optimización, lo que permite una convergencia más rápida y un ajuste más preciso de los parámetros del modelo (Friedman, 2001).

Manejo de datos faltantes: Una ventaja notable de XGBoost es su capacidad para manejar datos faltantes de manera eficiente, lo que lo hace adecuado para conjuntos de datos incompletos sin intentos adicionales (T. Chen y Guestrin, 2016).

Métricas de evaluación flexibles: XGBoost permite el uso de una amplia variedad de métricas de evaluación para optimizar el modelo, lo que lo convierte en una herramienta versátil tanto para problemas de clasificación como de regresión (T. Chen y Guestrin, 2016).

C. Aplicaciones de XGBoost

XGBoost ha sido ampliamente utilizado en diversas aplicaciones, desde la predicción de riesgos financieros hasta la medicina personalizada y el análisis de imágenes. Su efectividad para manejar grandes volúmenes de datos con características complejas lo hace muy adecuado para tareas en las que otros modelos más simples podrían fallar (Kaggle, 2018).

En el contexto de la clasificación, XGBoost ha demostrado un rendimiento sobresaliente en la predicción de enfermedades, como el cáncer, donde se utiliza para identificar patrones en datos clínicos y de imagen (T. Chen y Guestrin, 2016). Asimismo, se ha aplicado exitosamente en problemas de predicción de fraude en tarjetas de crédito y otros dominios donde se requiere una clasificación precisa a partir de datos desequilibrados (Chawla et al., 2011).

1.1.10 LightGBM

LightGBM (Light Gradient Boosting Machine) es una librería de aprendizaje automático de código abierto desarrollada por Microsoft que

implementa el algoritmo de gradient boosting. Al igual que XGBoost, LightGBM busca optimizar el proceso de boosting de árboles de decisión, pero con un enfoque en la eficiencia, especialmente cuando se trabaja con grandes volúmenes de datos. Desde su lanzamiento, ha sido altamente apreciado por su capacidad de manejar grandes bases de datos con alta velocidad y precisión (Ke et al., 2017). Debido a su alto rendimiento y eficiencia, LightGBM ha ganado popularidad en aplicaciones que requieren modelos predictivos rápidos y efectivos, siendo una herramienta común en competencias de ciencia de datos y aplicaciones de la industria.

A. Principios Fundamentales de LightGBM

LightGBM es una implementación eficiente del algoritmo de gradient boosting, similar a XGBoost, pero con ciertas diferencias clave en su implementación que lo hacen particularmente adecuado para datasets grandes y complejos. Al igual que en otros enfoques de boosting, se entrenan múltiples árboles de decisión de manera secuencial para corregir los errores de los árboles previos (Friedman, 2001). Sin embargo, LightGBM introduce varias innovaciones que mejoran tanto su velocidad como su capacidad de manejar grandes volúmenes de datos.

Split basado en histogramas: Una de las principales innovaciones de LightGBM es su uso de histogramas para realizar las divisiones en los árboles de decisión. En lugar de evaluar todas las posibles divisiones de los datos, LightGBM agrupa los valores de las características en intervalos discretos y evalúa solo las divisiones dentro de esos intervalos. Esto reduce significativamente el tiempo de entrenamiento y la memoria necesaria para manejar grandes conjuntos de datos (Ke et al., 2017).

Crecimiento de árboles en hojas (Leaf-wise Growth): A diferencia de otros algoritmos de boosting, que crecen los árboles de manera nivel por nivel (Depth-wise), LightGBM utiliza una estrategia leaf-wise, en la que selecciona la división de hoja que más reduce el error. Este enfoque permite una mayor precisión en el ajuste del modelo con menos árboles, pero puede resultar en un mayor riesgo de sobreajuste si no se controla adecuadamente (Ke et al., 2017).

Regularización y optimización: LightGBM incluye técnicas de regularización, como la poda de árboles y la limitación de la profundidad de los mismos, lo que ayuda a evitar el sobreajuste. Además, incorpora mejoras en la optimización, como el uso de histogram-based algorithms y técnicas de paralelización que permiten un entrenamiento más rápido y eficiente, especialmente en grandes volúmenes de datos.

B. Características de LightGBM

Eficiencia en términos de memoria y tiempo de entrenamiento: Gracias al uso de histogramas y la optimización en la construcción de árboles, LightGBM es notablemente más rápido y menos demandante en cuanto a memoria que otros algoritmos de boosting como XGBoost, especialmente en grandes conjuntos de datos. Esta característica es crucial para la investigación en áreas como el análisis de datos a gran escala o el procesamiento de grandes volúmenes de información.(Ke et al., 2017) .

Manejo de características categóricas: LightGBM tiene una ventaja importante al tratar variables categóricas de forma directa, sin necesidad de aplicar transformaciones como la codificación one-hot. Esto permite un manejo más eficiente de las características categóricas, especialmente cuando se trabaja con conjuntos de datos que contienen una gran cantidad de variables categóricas (Ke et al., 2017).

Paralelización y distribuido: LightGBM se beneficia de un modelo de paralelización eficiente que le permite realizar el entrenamiento en múltiples núcleos o incluso en sistemas distribuidos, lo que lo hace adecuado para su uso en entornos de computación de alto rendimiento (Ke et al., 2017).

C. Aplicaciones de LightGBM

LightGBM se ha utilizado con éxito en diversas áreas, como la predicción de riesgos financieros, la clasificación de imágenes y la segmentación de clientes. Gracias a su eficiencia y capacidad para manejar grandes volúmenes de datos, ha sido una herramienta popular en competiciones de machine learning, especialmente en plataformas como

Kaggle, donde los datos son de gran escala y complejidad. Además, se ha empleado en la predicción de enfermedades en el ámbito de la salud, así como en la detección de fraudes en sistemas bancarios (Ke et al., 2017).

En particular, en el campo de la clasificación de grandes volúmenes de datos, como en el análisis de datos de series temporales o la predicción de comportamientos en redes sociales, LightGBM ha demostrado ser una opción robusta debido a su rápida convergencia y capacidad para manejar relaciones complejas en los datos (T. Chen y Guestrin, 2016)

1.1.11 Redes Neuronales Artificiales (ANN)

Las Redes Neuronales Artificiales (ANN, por sus siglas en inglés) son un modelo computacional inspirado en la estructura y el funcionamiento del cerebro humano (LeCun et al., 2015). Se componen de unidades llamadas neuronas, que están organizadas en capas. Las ANN son fundamentales en el campo del aprendizaje profundo y el aprendizaje automático, y se utilizan en una amplia gama de aplicaciones, desde el reconocimiento de patrones hasta la predicción de series temporales y la clasificación de imágenes. El éxito de las ANN en tareas complejas, como el procesamiento de lenguaje natural o el análisis de datos no estructurados, ha consolidado su rol en el desarrollo de sistemas inteligentes (LeCun et al., 2015).

A. Estructura y Funcionamiento de las Redes Neuronales

Una red neuronal típica consta de tres tipos de capas:

Capa de entrada (Input layer): Esta capa recibe los datos de entrada que serán procesados por la red neuronal. Cada neurona en esta capa representa una característica de los datos (LeCun et al., 2015).

Capas ocultas (Hidden layers): Son las capas intermedias entre la entrada y la salida. Cada neurona en estas capas realiza una combinación ponderada de los datos de entrada, la cual es transformada mediante una función de activación. Estas capas permiten que la red aprenda representaciones complejas de los datos (LeCun et al., 2015).

Capa de salida (Output layer): Esta capa produce el resultado final del modelo, que puede ser una clasificación, predicción o decisión basada en la tarea específica (LeCun et al., 2015).

Las conexiones entre las neuronas están representadas por pesos que se ajustan durante el entrenamiento para minimizar el error en la salida del modelo.

B. Funcionamiento Matemático

El funcionamiento básico de una neurona en una red neuronal se describe mediante la siguiente fórmula:

$$y = f \left(\sum_{i=1}^n w_i x_i + b \right)$$

- y es la salida de la neurona.
- w_i son los pesos de las conexiones.
- x_i son las entradas de la neurona.
- b es el sesgo.
- f es la función de activación, como la sigmoide, ReLU (Rectified Linear Unit), entre otras.

Durante el entrenamiento, los pesos w_i y el sesgo b se ajustan utilizando algoritmos de optimización, como el descenso por gradiente, para reducir el error en la salida final de la red.

C. Funciones de Activación

Las funciones de activación son componentes clave en las ANN, ya que introducen no linealidad en el modelo, permitiendo que la red aprenda patrones complejos. Algunas de las funciones de activación más utilizadas son:

Sigmoide (Logística) proporciona una salida entre 0 y 1, ideal para problemas de clasificación binaria.

ReLU (Rectified Linear Unit) es una de las funciones más populares en redes neuronales profundas, ya que acelera el entrenamiento al evitar el problema de gradientes vanishing.

Tanh (Tangente Hiperbólica) similar a la sigmoide, pero produce salidas en el rango de -1 a 1.

D. Entrenamiento de las Redes Neuronales

El proceso de entrenamiento de una red neuronal implica ajustar los pesos y sesgos de la red para minimizar la función de pérdida, que mide la diferencia entre la salida predicha por la red y la salida real (etiquetas o valores conocidos). Esto se realiza mediante el descenso por gradiente:

$$w_i = w_i - \eta \frac{\delta L}{\delta w_i}$$

donde:

- η es la tasa de aprendizaje, que controla el tamaño del paso en cada iteración.
- L es la función de pérdida, como el error cuadrático medio o la entropía cruzada.

Este proceso se repite iterativamente utilizando un conjunto de entrenamiento hasta que la red alcanza una convergencia adecuada en los parámetros.

E. Tipos de Redes Neuronales

E.1 Perceptrón Multicapa (MLP)

Es la red neuronal más simple y básica, donde las neuronas están organizadas en varias capas completamente conectadas (feedforward). Este tipo de red es útil para tareas de clasificación y regresión.

E.2 Redes Neuronales Convolucionales (CNN)

Utilizadas principalmente en el procesamiento de imágenes, estas redes incluyen capas de convolución que permiten detectar patrones espaciales, como bordes y texturas.

E.3 Redes Neuronales Recurrentes (RNN)

Son adecuadas para tareas de procesamiento de secuencias, como traducción de idiomas o análisis de series temporales, ya que tienen conexiones hacia atrás que les permiten mantener información de estados anteriores.

F. Ventajas y Desventajas de las Redes Neuronales

F.1 Ventajas

Capacidad para aprender representaciones complejas de los datos. Eficaces en tareas no lineales. Versatilidad, utilizándose en una amplia variedad de aplicaciones.

F.2 Desventajas

Requieren grandes cantidades de datos para entrenarse adecuadamente. La interpretación de los modelos entrenados puede ser difícil, lo que puede afectar la transparencia en ciertos dominios, como la medicina o la justicia. Son propensas al sobreajuste, especialmente cuando no se regulan adecuadamente.

G. Aplicaciones de las Redes Neuronales

Las ANN tienen una amplia gama de aplicaciones en diferentes campos:

G.1 Visión por computadora

Se utilizan para el reconocimiento de imágenes, clasificación de objetos y detección de características en imágenes (LeCun et al., 2015). Procesamiento de lenguaje natural: En tareas como la traducción


automática, análisis de sentimientos y chatbots. Reconocimiento de voz:
En la conversión de voz a texto y en asistentes virtuales.

G.2 Medicina

Para el diagnóstico de enfermedades, análisis de imágenes médicas
y predicción de resultados de tratamientos.

Figura 5

Esquema neuronal de una capa en ANN



Nota. Esquema de una red neuronal simple con una capa de entrada, una capa oculta y una capa de salida.

1.2 Antecedentes

1.2.1 Internacionales

Ziamba et al. (2021) tiene como objetivo examinar la efectividad de varias técnicas de ciencia de datos en cuestión de apoyo a la decisión crediticia considerando el factor económico bajo un escenario afectado por el COVID-19, de tal manera que se obtenga el modelo que permita tomar la decisión más acertada. En particular, se diseñó la canalización de procesamiento, que consiste en métodos para re-muestreo de datos, discretización de características, selección de características y clasificación binaria. El análisis de viabilidad de los modelos seleccionados se realizó mediante experimentos rigurosos con datos reales que describen la capacidad del cliente para pagar el préstamo, se analiza el impacto de la selección de características en los resultados de la clasificación binaria y el impacto del re-muestreo de datos con discretización de características. Los resultados indican que la técnica de selección por *random forest* produce un

rendimiento de 84 % superior con respecto a otras técnicas como redes bayesianas, algoritmo KNN, arboles de decisión C4.5.

Milojević y Redzepagic (2021) busca explorar la posibilidad de una implementación exitosa de la gestión del riesgo crediticio especialmente la probabilidad default de un crédito, pero teniendo en cuenta los desafíos y problemas que podrían ocurrir, así como las posibles soluciones para los desafíos económicos y financieros globales contemporáneos, incluidos los causados por la crisis del COVID-19. Particularmente bajo la potencialidad de la inteligencia artificial y el aprendizaje automático. Se procesa información de la inversión de montos de dinero y se aplica un stress testing considerando dos escenarios, el primero sin considerar herramientas de inteligencia artificial o aprendizaje automático o aprendizaje profundo, y el segundo donde se considera las herramientas. Según el marco de trabajo presentado los resultados sugieren en una mejor gestión de riesgos, disminución de costos, procesos más rápidos y mejores servicios al cliente, aplicando los modelos de inteligencia artificial o aprendizaje automático o aprendizaje profundo.

Xia et al. (2021) proponen un modelo de puntuación de crédito dinámico novedoso denominado *SurvXGBoost* basado en el enfoque del árbol de decisiones que impulsa el gradiente de supervivencia o el aumento de gradiente (GBDT). Se espera que la propuesta, que combina el análisis de supervivencia y el enfoque GBDT, mejore la predictibilidad de la probabilidad default en relación con los modelos estadísticos de supervivencia (Cox PH y RSF). El método propuesto se compara con varios modelos de referencia comunes en un conjunto de datos de créditos consumo del mundo real. Los resultados de la validación fuera de muestra y fuera de tiempo indican que *SurvXGBoost* supera los puntos de referencia en términos de predictibilidad y costo de clasificación errónea. La incorporación de variables macroeconómicas puede mejorar aún más el desempeño de los modelos de supervivencia. La validación del modelo se da mediante varias medidas de evaluación, la más relevantes es verificación de la curva ROC, donde el índice es 0,6808.

Krichene (2017) tiene como objetivo abordar la cuestión de la predicción de incumplimiento (probabilidad default) de los créditos a corto plazo, para un

banco comercial tunecino. Para el cual se utiliza una base de 924 registros de créditos para el sector industrial y se utilizó el algoritmo clasificador bayesiano y los resultados muestran que la buena tasa de clasificación es del orden del 63,85 por ciento. La probabilidad de incumplimiento se explica por las variables que miden los indicadores de capital de trabajo, apalancamiento, solvencia, rentabilidad y flujo de caja. El resultado muestra que el área bajo el criterio de la curva (AUC) es del orden del 69 %.

Florez-Lopez y Ramon-Jeronimo (2014) introduce que existe la posibilidad de identificar la probabilidad default con escasos y desequilibrados datos usando desde luego aprendizaje automático, el modelado de estos conjuntos de datos desequilibrados es particularmente problemático con carteras pequeñas en las que la ausencia de información aumenta el error de instalación específico. Entonces se explora la idoneidad de las estrategias cooperativas para la gestión de PLD (carteras de bajo incumplimiento) tan escasos, utilizando dos conjuntos de datos de consumidores de crédito del mundo real. El rendimiento se evalúa en términos de poder discriminatorio fuera de muestra y fuera de tiempo, calibración de PD y estabilidad. Los resultados indican que los enfoques combinacionales basados en estrategias ajustadas por correlación son prometedores, en este caso la cooperación entre las técnicas de Regresión Lineal y Maquinas de vectores soporte (SVM) con 93 % de *accuracy*.

Coenen et al. (2020) realiza un estudio sobre identificar la probabilidad default (PD) considerando información de registros de créditos rechazados sin etiquetar, que puedan ayudar a mejorar un clasificador que solo se entrena en registros de créditos concedidos, utilizando aprendizaje semi-supervisado. La investigación contempla las circunstancias de un modelo entrenado en las instancias otorgadas, con resultado conocido, puede usarse en todas las instancias posibles. Para esto, se cree que un modelo debe indicar cuándo no puede predecir el resultado de manera confiable. Es decir, debe abstenerse de hacer predicciones sobre instancias distintas de aquellas en las que fue entrenado. Se evalúa un modelo propuesto por Geifman y El-Yaniv denominado SGR y se contrasta con una metodología ya conocida como es Random Forest, la medición del índice de efectividad está dada por la evaluación matriz de confusión y el set de datos se obtiene de la librería OpenML. Los resultados muestran que trabajar de manera

supervisada con registros de créditos aceptados como ya conocidos, un *accuracy* del 99,31 %, aunque este resultado depende mucho del set de información con el que se entrena y prueba, puesto que hubo dentro de las experimentaciones set de datos que mandaban un *accuracy* de 76,34 %.

Sheikh et al. (2020) Un enfoque muy importante en el análisis predictivo se utiliza para estudiar el problema de predecir los morosos de préstamos: el modelo de regresión logística. Los datos se recopilan del Kaggle (librería de set de datos) para su estudio y predicción. Se han realizado modelos de regresión logística y se calculan las diferentes medidas de rendimiento. Los modelos se comparan sobre la base de las medidas de rendimiento, como la sensibilidad y la especificidad. Los resultados finales han demostrado que el modelo produce resultados diferentes. El modelo es marginalmente mejor porque incluye variables (atributos personales del cliente como edad, propósito, historial crediticio, monto del crédito, duración del crédito, etc.) además de la información de la cuenta corriente (que muestra riqueza de un cliente) que deben tenerse en cuenta para calcular correctamente la probabilidad de incumplimiento del préstamo. Por lo tanto, mediante el uso de un enfoque de regresión logística, los clientes adecuados a los que se dirigirá para la concesión de préstamos pueden detectarse fácilmente mediante la evaluación de su probabilidad de incumplimiento del préstamo. El modelo concluye que un banco no solo debe apuntar a los clientes ricos para otorgar préstamos, sino que también debe evaluar los otros atributos de un cliente que juegan un papel muy importante en las decisiones de concesión de crédito y en la predicción de los morosos del préstamo.

Shoumo et al. (2019) propone un modelo de aprendizaje automático que puede evaluar con precisión el riesgo crediticio y predecir posibles incumplimientos de préstamos para las instituciones crediticias. Realiza un análisis comparativo utilizando algoritmos de aprendizaje supervisado sintonizados como *Support Vector Machine*, *Random Forest*, *Extreme Gradient Boosting* y *Logistic Regression* para identificar a los morosos. La eliminación de características recursivas con validación cruzada y el análisis de componentes principales se han utilizado para la reducción de dimensionalidad. Se han utilizado métricas como la puntuación F1, la puntuación AUC, la precisión de la predicción, la precisión y la recuperación para evaluar cada modelo. Entre todos los modelos,

la combinación de una máquina de vectores de soporte ajustada y la eliminación de características recursivas con validación cruzada han demostrado ser muy prometedoras para identificar a los morosos de préstamos. Por lo tanto, el modelo propuesto puede ayudar a las instituciones financieras a identificar con precisión a los morosos de préstamos y evitar que incurran en pérdidas adicionales. Posterior a la discusión respectiva se ha concluye que el algoritmo de SVM es quien presenta mejor rendimiento al predecir la PD con un *recall* de 85 %.

Patel et al. (2020) utiliza algoritmos de minería de datos para predecir los posibles incumplidores a partir de un conjunto de datos que contiene información sobre las solicitudes de préstamos hipotecarios, lo que ayuda a los bancos a tomar mejores decisiones en el futuro. La conclusión derivada de tales evaluaciones ayuda a los bancos y otras instituciones financieras a disminuir sus pérdidas y eventualmente aumentar el número de créditos. Por lo tanto, es vital construir un modelo que tenga en cuenta los diferentes aspectos de un solicitante y obtenga un resultado con respecto al solicitante en cuestión. Trabaja con un set de datos de 64000 registros de créditos, obtenidos de la librería de set de datos Kaggle. Los algoritmos a evaluar el mayor rendimiento son RL, GB, CBC, RF y los índices de evaluación son *Accuracy*, *Precision* y *F1-score*. Con el set de datos en el modelo, posterior a la discusión se concluye que GB es quien posee mejor rendimiento con 84 % de accuracy.

Barua et al. (2021) implementa el algoritmo *CatBoost* que se utiliza para predecir incumplimientos de préstamos junto con un módulo de verificación de documentos utilizando *Tesseract* y Camelot y también un módulo de préstamos personalizado, mitigando así el riesgo de las instituciones financieras en la emisión de préstamos a morosos y clientes no autorizados. Dicho modelo evaluará los datos de sus clientes en función de ciertos parámetros y generará un resultado preciso basado en esa evaluación. La información se obtiene del repositorio Kaggle, que es una central de datos india, al cual se ha trabajado la información acorde al requerimiento del modelo. Los algoritmos a evaluar son el *CatBoost Classifier* y *PyTesseract* de Google que en si utiliza RF. Los resultados se trabajan en casos de estudio, donde los veredictos son cualitativos respecto a si el crédito postulado es bueno o no; sin embargo, se puede observar directamente que existe

un indicador Probabilidad Default. La conclusión es clara con respecto al modelo y los datos presentados, *CatBoost Classifier* cumple con las expectativas.

Addo et al. (2018) construyen clasificadores binarios basados en modelos de aprendizaje profundo y de máquina sobre datos reales para predecir la probabilidad de incumplimiento del préstamo. Las 10 principales características importantes de estos modelos se seleccionan y luego se utilizan en el proceso de modelado para probar la estabilidad de los clasificadores binarios comparando su desempeño en datos separados. Observamos que los modelos basados en árboles son más estables que los modelos basados en redes neuronales artificiales multicapa. Esto abre varias preguntas relativas al uso intensivo de sistemas de aprendizaje profundo en las empresas. Trabajan con información crediticia de 117 mil registros, los cuales han pasado por un proceso de normalización, los modelos a medir son RF, GB y ANN (redes neuronales) sin embargo la implementación de la red neuronal esta segmentada en 4 variantes según el número de neuronas y numero de capas, las cuales aprende con *Deep learning*. La medir la calidad del modelo se aplica la curva ROC. El algoritmo con un mejor rendimiento es *Gradient Boost* (aumento de gradiente) con un *accuracy* del 92 %, considerando el set de datos.

Ampountolas et al. (2021) la investigación compara varios algoritmos de aprendizaje automático con datos reales de microcréditos para probar su eficacia a la hora de clasificar a los prestatarios en varias categorías de crédito. Demostramos que los clasificadores de clases múltiples listos para usar, como los algoritmos forestales aleatorios, pueden realizar esta tarea muy bien, utilizando datos fácilmente disponibles sobre los clientes (como edad, ocupación y ubicación). Esto presenta un medio económico y confiable para las instituciones de microcrédito en todo el mundo en desarrollo con el cual evaluar la solvencia crediticia en ausencia de un historial crediticio o bases de datos crediticias centrales. El set de datos para el entrenamiento y pruebas fue obtenido de un instituto de microfinanzas en Ghana, y tuvo un previo tratamiento de datos. Los algoritmos empleados para ser medidos en rendimiento son; DTC (Arbol de decisión), XTC (Extra Arbol de Clasificacion), RF (*random forest*), Adaboost, KNN y Perceptron multicapa. Para evaluar el modelo se utilizó la matriz de confusión y los índices son *Precision*, *Recall*, *F1- Score*, *Support*. Uno de los

aspectos importantes de la investigación es que presenta un análisis de sensibilidad el cual adicionalmente evalúa con la curva ROC y AUC. Finalmente, según los resultados y posterior a la discusión se concluye que el algoritmo de Random Forest presenta mejor rendimiento con un AUC de 0,82.

Coşer et al. (2019) mediante el uso de la metodología de minería de datos y algoritmos de aprendizaje automático, se desarrollaron una serie de modelos predictivos utilizando clasificadores como *LightGBM*, *XGBoost*, *Logistic Regression* y *Random Forest* con el fin de evaluar la probabilidad de que un cliente ingrese un préstamo predeterminado. Se crearon tres escenarios de muestreo para comparar la clasificación entre conjuntos de datos desequilibrados y equilibrados. Además, se realizó un análisis de comparación de modelos para identificar el mejor clasificador considerando las métricas de rendimiento del modelo: puntuación AUC, Precisión, Recuperación y Exactitud. Los mejores resultados se observaron para el clasificador óptimo de Random Forest aplicado en el muestreo de sub-sobre del escenario combinado, con un AUC representativo de 0,89.

Y.-Q. Chen et al. (2018) presentan su estudio enfocado en un método de submuestreo híbrido que combina la agrupación, la medida de sensibilidad estocástica y las redes neuronales de función de base radial. Se utilizan datos reales de incumplimiento de préstamos de una empresa P2P en China para validar el rendimiento de nuestro método. Los resultados de los experimentos demuestran que nuestro enfoque produce un mejor rendimiento de generalización. El algoritmo de mayor enfoque en el estudio es el denominado DSUS, el cual efectivamente resulta ser el de mayor rendimiento, la evaluación del modelo está dado por una matriz de confusión y los índices son Recall, precisión, y G-Mean.

Zeng et al. (2017) este estudio construyó un modelo de riesgos competitivos para predecir el incumplimiento y el prepago al mismo tiempo mediante el uso de regresión logística. Los resultados pueden ser la base de gestión del negocio crediticio ejecutado por instituciones financieras. El set de datos trabajado contiene 18,995 registros donde se tomará el 90 % para entrenamiento y el 10 % para pruebas, el algoritmo a evaluar es únicamente Regresión Logística testeado con datos ya etiquetados, es decir aprendizaje supervisado. Otro de los retos es que el set de datos está segmentado en 3 partes,

donde cada segmento contiene un número diferente de variables, esto con el fin de detectar la importancia de las variables (esto explica del porqué solo se emplea una sola técnica). Finalmente se ha concluido que no se requiere todas las variables para pronosticar el default del crédito.

Yap et al. (2011) utilizaron datos de pago históricos de un club recreativo y establecieron técnicas de calificación crediticia para identificar a los posibles morosos de suscripciones de los miembros del club. Los resultados del estudio demostraron que ningún modelo supera a los demás entre un modelo de tarjeta de puntuación de crédito, una regresión logística y un modelo de árbol de decisiones. Cada modelo generó cifras de precisión casi idénticas.

Zhao et al. (2015) examinaron la precisión de una red neuronal de perceptrón multicapa (MLP) con respecto a la estimación de puntajes crediticios de manera eficiente. Los autores utilizaron un conjunto de datos crediticios alemán para entrenar y estimar la precisión del modelo. Sus resultados indicaron que un modelo MLP que contenía nueve unidades ocultas logró una precisión de clasificación del 87 %, superior a otros similares experimentos. Los resultados de su estudio demostraron la tendencia de la precisión de la puntuación de los modelos MLP al aumentar el número de unidades ocultas.

Petropoulos et al. (2023) estudiaron un conjunto de datos a nivel de préstamos de la economía griega para examinar el desempeño de la calidad crediticia y la cuantificación de la probabilidad de incumplimiento para un periodo evaluativo de 10 años. Los autores utilizaron un ejemplo extendido de clasificaciones de los modelos de aprendizaje automático incorporados frente a métodos tradicionales, como la regresión logística. Sus resultados identificaron que los modelos de aprendizaje automático habían demostrado ser superiores precisión de desempeño y pronóstico a través del ciclo de calificación crediticia financiera.

Provenzano et al. (2020) introdujo modelos de aprendizaje automático para componer la calificación crediticia y la estimación de predicción predeterminada. Utilizaron instrumentos financieros, como balances históricos, estatutos de quiebras y variables macroeconómicas de un conjunto de datos de Moody's. Utilizando modelos de aprendizaje automático, los autores observaron

excelentes resultados de rendimiento fuera de la muestra para reducir la probabilidad de quiebra o mejorar la calificación crediticia.

1.2.2 Nacionales

Canelo y Tocto (2018) se emplearon redes neuronales supervisadas, implementando tres modelos distintos, con el propósito de determinar la aceptación o el rechazo de solicitudes de crédito. El entrenamiento de estas redes se llevó a cabo utilizando datos de una entidad microfinanciera, los cuales comprendían un total de 15,569 registros, cada uno con 20 atributos. Para la construcción de los modelos, se utilizó la plataforma en la nube Microsoft Azure Machine Learning Studio, permitiendo la obtención de métricas de eficiencia y error que facilitaron la selección del modelo predictivo más adecuado. El modelo seleccionado puede ser aplicado en la automatización del proceso de evaluación de solicitudes de crédito en instituciones financieras.

1.2.3 Locales

Aceituno (2019) propone un modelo de predicción de riesgo crediticio para identificar el modelo que exhibe el mayor grado de precisión en la concesión de microcréditos. Trabajó con los modelos de Regresión Logística, *Random Forest*, *Support Vector Machine*, *Decision Tree* y *K-nearest Neighbors*. El modelo con mayor asertividad determinado fue *Support Vector Machine*.

CAPÍTULO II

PLANTEAMIENTO DEL PROBLEMA

2.1 Identificación del problema

El comportamiento de pago de los clientes del sector micro financiero en el Perú, se ha visto afectada por la recesión económica que generó la pandemia por el COVID-19, incrementando la mora crediticia (SBS, 2021) en un promedio del 9,6 % afectando los ingresos financieros de las entidades micro financieras y modificando su probabilidad default. Este ratio obedece a que muchos sectores económicos de la pequeña y micro empresa se vieron afectados al cerrar temporalmente sus negocios. Sin embargo, pasado 2 olas de contagio en un periodo de 14 meses (Diario Gestión, 2021); el sistema micro financiero del Perú en la actualidad presenta un dinamismo con tendencia de crecimiento debido a los esfuerzos de reactivación económica (MEF, 2021). Y considerando este comportamiento del mercado las empresas del mismo sistema micro financiero (Revista Microfinanzas, 2021) se requiere y es necesario diseñar modelos que identifiquen a nivel de portafolio la probabilidad default con técnicas de aprendizaje automático (Milojević y Redzepagic, 2021).

Existen investigaciones en otros países sin embargo no en un contexto nacional peruano. La identificación de la probabilidad default con un data set de créditos post crisis causado por una pandemia es un ejercicio que no es indiferente en países de Europa, como Suiza (Ziemba et al., 2021) dado que la pandemia tuvo un efecto mundial, entonces, es oportuno realizar el ejercicio en el ámbito nacional peruano, en el que se considera información también en el mismo sector financiero bajo un contexto de post pandemia. Se pretende realizar un mismo ejercicio considerando un contexto local nacional.

En el Perú el repositorio con información crediticia pública está dada por la SBS mediante el RCC (Registro Consolidado de Créditos). Se propuso un modelo de identificación de probabilidad default considerando datos escasos para el entrenamiento en un aprendizaje supervisado (Florez-Lopez y Ramon-Jeronimo, 2014) la información empleada contiene escasos datos públicos, emitidos en un repositorio de acceso público. Los resultados de la aplicación por los diferentes modelos de *Machine Learning*, fueron complementados con una calibración.

Para la precisión que se requiere de los periodos de información (out-of-time) y las casuísticas en los datos (out-of-sample) son validados con el modelo GBTD (árbol de decisión con aumento de gradientes) los resultados presentan un alto nivel de H measure (Xia et al., 2021). La información a tratar en el ámbito local, comprende información de varios periodos y casuísticas que están absortos de ser descubiertos con un modelo no probado en el Perú. La evaluación de resultados con la curva ROC se considera una de las de mayor confiables, para la técnica de redes neuronales basadas en redes neuronales (Krichene, 2017), es una de las mediciones que nos permitirá a encontrar la mejor técnica ajustada al dataset a evaluar. Y por otro lado estan las métricas de evaluación de modelos dados por una matriz de confusión, que son el *Accuracy*, *Precision*, *Recall* y *F1 Score*.

No existe una técnica específica de aprendizaje automático que nos permita claramente identificar la probabilidad default de un crédito postulado considerando información de la SBS (Ampountolas et al., 2021) por tanto es necesario la medición de varias técnicas de aprendizaje automático para identificar la de mayor rendimiento.

2.2 Enunciados del problema

2.2.1 Problema general

Considerando el contexto descrito se plantea la formulación del problema de la siguiente manera:

- ¿Cómo desarrollar un modelo de predicción de riesgo crediticio basado en Machine Learning que permita identificar con precisión la probabilidad de default de créditos otorgados en un contexto post-pandemia COVID-19, considerando las particularidades económicas y financieras del periodo?

2.2.2 Problemas específicos

- ¿Existe un proceso para construir un data set y cuáles son las variables ponderadas para hallar la probabilidad default de la información pública de créditos post COVID-19?
- ¿Cuál es el modelo que tiene mayor rendimiento al hallar la probabilidad default de un crédito con información post COVID-19?

2.3 Justificación

Los resultados que se plantea obtener de esta investigación, permitirán a priori identificar con el modelo de mayor rendimiento, a la probabilidad default de un crédito en admisión y además por otro lado permitirá identificar las variables con mayores relevancias en un dataset post COVID-19, generado de información pública; para entrenar un modelo de Machine Learning que identifique la probabilidad default de un crédito.

La implementación de modelos para identificar la probabilidad de default (PD) de los deudores, tal como lo recomiendan las Normas Internacionales de Información Financiera (NIIF) y los acuerdos de Basilea, es fundamental para la estabilidad y la salud del sistema financiero, dado que mejora la gestión del riesgo crediticio al dar mayor precisión del cálculo de provisiones para afrontar las perdidas esperadas, asegurando que el sector financiero tenga las suficientes reservas para afrontar y cubrir potenciales perdidas. Por otro lado, lejos de dar cumplimiento normativo a este acuerdo de Basilea, la implementación de modelos de PD mejora la transparencia de la información financiera de las entidades y facilita la supervisión regulatoria.

Los algoritmos de *Machine Learning* pueden procesar grandes cantidades de datos estructurados y no estructurados, identificando patrones complejos que son difíciles de detectar mediante análisis tradicionales. Y a su vez los modelos de *Machine Learning* pueden aprender y adaptarse continuamente a los cambios en el entorno económico y a las nuevas tendencias de comportamiento de los clientes. El uso de técnicas de *Machine Learning* facilita la implementación de modelos de PD más avanzados y personalizados.

Las empresas de sector micro financiero del Perú, al dar estudio a los resultados y generar una dimensión de aplicaciones acorde a las necesidades de implementación de productos acorde al nuevo perfil (simples) crediticio post COVID-19 del cliente pequeño y micro empresario peruano. Las empresas del sector micro financiero local podrán beneficiarse con una toma de decisiones con mayor asertividad y de esta manera centrarse en la competitividad de operaciones, de tal manera que se incremente los ingresos financieros.

La inteligencia artificial y el aprendizaje automático han aumentado influencia en el sector financiero, pero también en la economía en su conjunto. El impacto de la inteligencia artificial y el aprendizaje automático en la banca. La gestión de riesgos se ha

vuelto particularmente interesante después de la crisis financiera mundial. Los modelos de aprendizaje automático tienen potencial para respaldar medidas de mitigación para el contexto económico y financiero mundial contemporáneo desafíos, incluido el COVID-19 (Milojević y Redzepagic, 2021) .

La propuesta del presente estudio es la comparación de algoritmos de diferentes modelos de aprendizaje automático, al identificar el modelo con mayor precisión permitirá la implementación de un marco de aplicación para las empresas del sector micro financiero para identificar la PD, además que dará a conocer a la comunidad científica y académica una base para futuras investigaciones.

2.4 Objetivos

2.4.1 Objetivo general

- Desarrollar un modelo de predicción de riesgo crediticio, utilizando modelos de *Machine Learning*, que permita identificar de manera precisa la probabilidad de default de créditos otorgados en un contexto post-pandemia COVID-19, a partir de la construcción y análisis de un conjunto de datos detallado y representativo.

2.4.2 Objetivos específicos

- Determinar el procedimiento para obtener un dataset e identificar las variables con mayor poder informativo dentro de la información de créditos post impacto COVID-19 calibrado para obtener mayor precisión.
- Determinar el modelo de *Machine Learning* con mayor exactitud para predecir la probabilidad default de un crédito post impacto COVID-19.

2.5 Hipótesis

2.5.1 Hipótesis general

- El modelo de *machine learning*, *Random Forest* (RF) permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.

2.5.2 Hipótesis específicas

- El modelo de *machine learning* SVM permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.
- El modelo de machine learning Random Forest permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19
- El modelo de machine learning Logistic Regression permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.
- El modelo de machine learning ANN permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.
- El modelo de machine learning LightGBM permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.
- El modelo de machine learning XGBOOST permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.

CAPÍTULO III

MATERIALES Y MÉTODOS

3.1 Lugar de estudio

Se llevará a cabo en la ciudad de Puno en Perú a 3,820 metros sobre el nivel del mar. Con una población de 1 226 353 de habitantes (INEI, 2023).

3.2 Población

En la presente investigación la población estará constituida por 1.2 Millones de registros de una entidad del sector financiero en el producto consumo retail; obtenida en el RCC (información pública emitida por la Superintendencia de Banca y Seguro del Perú). El 80 % de la información será empleada para el entrenamiento y el 20 % para las pruebas.

3.3 Muestra

El tipo de selección muestral es no probabilístico, por conveniencia para la investigación (Hernandez Sampieri et al., 2014) . Debido a que se realizó una selección en base a juicio experto de los registros crediticios a evaluar, por lo que se considera el total de la población.

3.4 Método de investigación

La investigación es no experimental de tipo transversal, su propósito es describir variables y analizar su incidencia e interrelación en un momento dado (Sampieri et al. 2014), en este caso en el periodo de un año, de Enero 2021 a Diciembre 2021. Se ha empleado un diseño de investigación descriptiva comparativa, se han establecido variables y propiedades de un determinado fenómeno para ser analizados y comparados. En este estudio el objetivo es conocer el mejor modelo de *Machine Learning* que identifique la probabilidad default de un crédito post COVID-19, para el cual se ha comparado el nivel de exactitud de los modelos más usados de *Machine learning*.

3.5 Descripción detallada de métodos por objetivos específicos

Especificamos en tres actividades correlativas la metodología aplicada para hallar el modelo de *Machine Learning* (Aceituno, 2019) que identifique la probabilidad default

de un crédito post COVID-19. La primera actividad es el diagnóstico del flujo de información y revisión del proceso de segmentado por perfiles de los registros de la población de créditos. Este proceso ayudará a determinar las variables que influyen para la aplicación de un perfil de crédito dependiendo del producto crediticio.

En la siguiente actividad, que es continua a la primera, esta principalmente enfocada en el entrenamiento de los modelos de *Machine Learning* seleccionados para la investigación, esto a partir de la data set producto de la primera actividad.

Finalmente entraremos en la actividad de evaluación, donde se revisará el comportamiento de las métricas obtenidas e identificar el modelo con mayor exactitud.

3.5.1 Diagnóstico

En este proceso entenderemos el flujo de información para la generación de segmento de información crediticia, esta segmentación es propia de la entidad financiera en la cual se realiza la investigación, que tiene el fin de dar un perfil al crédito de acuerdo a los campos de información obtenidos desde el proceso de otorgamiento de crédito; el perfil tiene una propia denominación. La parte investigadora se hará de esta información pre procesada para considerarlo en el data set que será el modelo de datos final.

Dentro de este proceso también implica la revisión de la literatura para la obtención de la variables teóricas o categóricas, para esto se ha investigado el proceso de toma y gestión de información crediticia desde la admisión. Finalmente se realizó el análisis de variables empíricas y categóricas a través contraste de variables.

Para mapear el flujo de información se utilizó la herramienta de diagramación de procesos Bizagi (Bizagi, 2019) y (Draw.io, 2024).

3.5.2 Evaluación

En este proceso se pretende determinar el modelo con mayor exactitud en la identificación de la probabilidad default. Las métricas a contrastar son Accuracy (Acc), Precision (Pre), Recall (Rec), F1 Score (F1) y AUC ROC (AUC). Los cuales, de acuerdo con la revisión de antecedentes, son los que frecuentemente se han empleado.

Tabla 1

Métricas empleadas para evaluación de modelos de Machine Learning


Métricas Empleadas	ACC	REC	PRE	F1	AUC
Aida Krichene (2017)	X				X
Yufei XIA Et. Al (2020)					X
Apostolos Ampountolas (2021)	X	X	X	X	X
Mohammad Ahmad Sheikh (2020)	X	X	X	X	
Bhoomi Patel (2020)	X		X	X	

3.5.3 Implementación

El fin de esta actividad dentro de la metodología es la selección definitiva de las variables como conjunto de datos para el modelo, que previamente en la actividad de diagnóstico se había investigado. En esta etapa realizamos la limpieza; que comprende el tratamiento información que podría sesgar el modelo, tales como vacíos (nulos), caracteres especiales no categorizadas entre otros. Todo esto comprende el pre procesamiento de datos para el entrenamiento. Para que la información se escalable utilizaremos dentro del lenguaje Python la función de *labelencoder* de la librería *sklearn.preprocessing*.

Figura 6

Modelo One-hot para el preprocesado



Para el entrenamiento de los modelos se ha previsto utilizar un total de seis técnicas de *machine learning* para el aprendizaje supervisado, los cuales se listan a continuación; Regresión Logística (LR), Random Forest (RF), Artificial Neural Network (ANN), LightGBM (LGBM), Extreme Gradient Boost (XGBOOST), Support Vector Machines (SVM). Estos modelos fueron elegidos posterior a la revisión de investigaciones similares donde el uso frecuente es común entre ellos, como se observa en la tabla 2.

Tabla 2

Modelos empleados en investigaciones antecedentes


Referencia	LR	RF	ANN	LGBM	XGBOOST	SVM	KNN
Peter Martey Addo, et al. (2018)	X	X		X			
Bhoomi Patel et al. (2020)	X	X			X		
Ya-Qi Chen et al. (2018)	X	X			X		
Alexandru Coser et al. (2019)	X	X		X	X		
Sujoy Barua et al. (2021)					X		
Apostolus Ampountolas et al. (2021)		X			X		X
Mohammad Ahmad et al. (2020)	X					X	X

Referencia	DTREE	GBC	MR	CBC
Peter Martey Addo, et al. (2018)			X	
Bhoomi Patel et al. (2020)				X
Ya-Qi Chen et al. (2018)				
Alexandru Coser et al. (2019)				
Sujoy Barua et al. (2021)		X		X
Apostolus Ampountolas et al. (2021)	X			
Mohammad Ahmad et al. (2020)				

El proceso de entrenamiento de los modelos de *machine learning* se realizará con el data set definitivo posterior al pre procesado respectivo, el entrenamiento es un ejercicio que se realizara con cada modelo especificado y los resultados serán acopiados independientemente.

Figura 7

Entrenamiento de modelos de Machine Learning para la investigación



CAPÍTULO IV

RESULTADOS Y DISCUSIÓN

4.1 Resultados


4.1.1 Resultado conforme al primer objetivo

A. Revisión del flujo de información

Para entender el flujo de información dentro de la investigación se revisó el proceso macro del otorgamiento de créditos como tal. En sector financiero la emisión de créditos sigue un patrón usual en su proceso según lo expuesto por Aceituno, 2019.

Figura 8

Flujo de información en el proceso de otorgamiento




Como se observa en la figura 8 en el proceso de obtención de información base, se tendrá la información de la persona a quien se potencialmente se otorgará el crédito. Esta información es útil para la evaluación de otorgamiento de crédito y su posterior aprobación para finalmente generar la operación de desembolso. Hasta aquí se ha recopilado información compuesta por varios campos, que generalmente

son información cualitativa del cliente y en algunos casos será cuantitativa como en el caso de Edad (por ejemplo).

La información inherente en el estado ex ante del crédito viajara al estado ex post del crédito adicionando más campos; que son las condiciones con la que se dieron la operación de desembolso de crédito. Sumado a ello también se observa campos de información que variarán con el tiempo. El esquema puede verse en la figura 9.

Figura 9

Esquema de transición de información de Ex Ante a Ex Post



Cuando se menciona que los valores de los campos son variables con el tiempo, se refiere a información que irá cambiando mes a mes debido al cumplimiento del pago según cronograma pactado bajo contrato en la operación del desembolso. A continuación, detallaremos los campos y su información en los estados Ex Ante y Ex Post del crédito.

A.1 Información de campos Ex ante.

Presentamos la información en la tabla 3.

Tabla 3

Campos de información antes del desembolso de crédito

Información Ex Ante	Descripción
Estado Civil	Estado Civil de la persona
Ingreso - Ventas	El monto neto en ingreso o ventas
Oficio	Oficio o profesión de la persona
Ubigeo	Código de ubigeo según SBS
Edad	Edad de la persona
Sexo	Sexo en genero de la persona

Información Ex Ante	Descripción
Numero Dependientes	Cantidad de personas que dependen del contrayente
Departamento	Nombre departamento de ubicación
Provincia	Nombre de la provincia de ubicación
Distrito	Nombre del distrito de ubicación
Teléfono	Número telefónico (celular)
Dirección	Dirección de vivienda de la persona
Nivel Educación	Nivel educación actual de la persona
Antigüedad Laboral	Antigüedad en años en el centro laboral
Antigüedad Domiciliaria	Antigüedad en años viviendo en la dirección
Tipo Vivienda	Tipo de vivienda según INEI
Situación Laboral	Situación Dependiente / Independiente
Actividad Económica	Actividad económica con la que genera los ingresos
Agencia	Agencia donde solicita el crédito
Línea Producto	Es el producto a la que el cliente aplicará para el crédito
Numero Entidades	Número de entidades reportadas en central de riesgo
Calificación RCC	Calificación SBS reportada
Saldo RCC	Saldo actual en créditos directos
Antigüedad RCC	Numero de meses reportado en el RCC en una ventana de 24 meses
Antigüedad Financiera	Numero de meses reportado en el buró interno en una ventana de 24 meses

Nota. RCC es el acrónimo de Reporte Crediticio del Deudor, una central de riesgos establecida por la Superintendencia de Banca y Seguros (SBS)

A.2 Información de campos Ex post

Como se especificó antes, la información posterior al desembolso estará conformada por la información que viene de Ex ante, y se sumara la información de las condiciones del crédito.

Tabla 4

Información de campos posterior al desembolso

Información Ex Post	Descripción	Tipo Campo
Estado Civil	Estado Civil de la persona	
Ingreso - Ventas	El monto neto en ingreso o ventas	
Oficio	Oficio o profesión de la persona	
Ubigeo	Código de ubigeo según SBS	
Edad	Edad de la persona	
Sexo	Sexo en genero de la persona	
Numero Dependientes	Cantidad de personas que dependen del contrayente	
Departamento	Nombre departamento de ubicación	
Provincia	Nombre de la provincia de ubicación	
Distrito	Nombre del distrito de ubicación	
Telefono	Número telefónico (celular)	
Dirección	Dirección de vivienda de la persona	
Nivel Educación	Nivel educación actual de la persona	
Antigüedad Laboral	Antigüedad en años en el centro laboral	
Antigüedad Domiciliaria	Antigüedad en años viviendo en la dirección	
Tipo Vivienda	Tipo de vivienda según INEI	
Situación Laboral	Situación Dependiente / Independiente	
Actividad Económica	Actividad económica con la que genera los ingresos	
Agencia	Agencia donde solicita el crédito	
Numero Entidades	Número de entidades reportadas en central de riesgo	
Calificación RCC	Calificación SBS reportada	
Saldo RCC	Saldo actual en créditos directos	
Antigüedad RCC	Numero de meses reportado en el RCC en una ventana de 24 meses	
Antigüedad Financiera	Numero de meses reportado en el buró interno en una ventana de 24 meses	
Monto Desembolso	Monto del crédito otorgado	Estático
Fecha Desembolso	Fecha en la que se desembolsó el crédito	Estático
Nombre Producto	Nombre del producto crediticio otorgado	Estático
Línea Producto	Es el producto a la que el cliente aplicará para el crédito	Estático
Código Producto	Código en número del producto	Estático
Sub Producto	en caso el producto tenga varias divisiones	Estático
Plazo	plazo en número de meses pactado el crédito	Estático
Código Agencia	código en numero de la agencia donde se desembolsó el crédito	Estático

Información Ex Post	Descripción	Tipo Campo
Tasa Interés	Tasa de interés compuesto con la se pactó el crédito	Estático
Campaña	Denominación de la campaña en caso hubiere	Estático
Código Campaña	Código interno en número de la campaña	Estático
Estado reprogramado	En caso de que el crédito haya tenido una reprogramación de cronograma	Estático
Retail	Denominación de la empresa retail que otorga el crédito	Estático
Marca	Marca del producto físico obtenido a crédito	Estático
Región / Zona	Denominación de región o zona interna	Estático
Nombre funcionario	Nombre del funcionario que gestionó el crédito	Estático
Tiempo Gracia	Tiempo en meses exonerado de tasa de interés	Estático
Estado Contable	Denominación de estado contable normativa según la SBS	Variable con el Tiempo
Número de cuotas pagadas	Numero de cuotas pagadas del cronograma hasta la fecha actual	Variable con el Tiempo
Número de cuotas impagas	Numero de cuotas impagas del cronograma a la fecha actual	Variable con el Tiempo
Monto Saldo	Saldo capital pendiente de pago	Variable con el Tiempo
Monto Saldo Vencido	Saldo capital pendiente de pago que no fue pagado según cuota de cronograma	Variable con el Tiempo
Días de atraso	Días de atraso de la cuota sin pago vencida en el cronograma	Variable con el Tiempo
Maduración	Numero de meses transcurridos posterior a la fecha de desembolso	Variable con el Tiempo
Provisiones regulatorias	monto que exige la SBS para efectos de mitigar el riesgo de crédito	Variable con el Tiempo

La variabilidad en función al tiempo esta dado por cada cierre mensual, entonces, los campos “variables con el tiempo” podrían cambiar los valores mensualmente; como es en caso de “Estado Contable” que depende de cuantos días de atraso cerro en el mes, en caso fuera >90 días entonces el valor será “Vencido”. Los otros valores que puede tomar son “Vigente”, “Judicial”, “Refinanciado Vencido”, “Refinanciado Vigente”.

En el caso del campo Número de Cuotas pagadas y Numero de Cuotas impagas variara en función de si se pagó la cuota cronograma

según corresponda la fecha, si se realizó el pago en número de cuotas pagadas incrementar y el número de cuotas impagas disminuirá. En un inicio el número de cuotas pagadas es cero.

El campo “Monto Saldo”, es capital en términos de moneda local que a medida que se paga las cuotas ira disminuyendo hasta 0. En caso una cuota no se pague durante más de 90 días, entonces el campo “Monto saldo vencido” tendrá el mismo valor que “Monto Saldo”.

Los días de atraso, se cuentan a partir del vencimiento de la cuota cronograma, y se reportara lo que haya contado hasta el cierre del mes (último día del mes).

También exponemos la información de los campos que son posteriores al desembolso, sin embargo, son producto de un cálculo donde los factores son los campos previamente mostrados, tanto en ex ante como ex post.

Tabla 5

Información de campos calculados posterior al desembolso

Información Calculada Ex Post	Descripción	Tipo Campo
Mora	Saldo Vencido / Saldo Capital	Variable Calculado
Cosecha en saldo (M)	Sumatoria (Saldo Capital del mes M) / desembolso del mes M	Variable Calculado
Cosecha en cuenta (M)	Sumatoria Cuentas con vencimiento / Total cuentas desembolsadas del mes M	Variable Calculado
PD (M)	Si los días de atraso superan los >60 al momento del mes M.	Variable Calculado
Cobertura Provisiones	Sumatoria Provisiones / Cartera Atrasada	Variable Calculado
Segmento	Fx(Antigüedad RCC, Antigüedad Financiera)	Estático Calculado
Perfil	Score de Fx(Antigüedad RCC, Antigüedad Financiera)	Estático Calculado

Nota: El valor M esta dado en función al campo Maduración (Tabla 4)

B. Análisis de las variables

Los campos revisando en el punto anterior, son potenciales variables de entrada para el set de entrenamiento. En este punto expondremos un análisis a las variables calculadas.


- Segmento: La segmentación de créditos se realiza en base a la parametrización de varios campos, en esta en la entidad financiera de estudio, considera la antigüedad en el RCC y antigüedad en la entidad. Los valores que puede mostrar son: Cliente Bancarizado, Cliente no Bancarizado y Cliente Recurrente.
- Perfil: es una división del campo anterior, el cual está en función al comportamiento de pagos y calificación SBS, en caso de Cliente Bancarizado, el perfil tomara los valores de Bancarizado A, Bancarizado B, hasta Bancarizado F. En caso de Cliente No Bancarizado de la misma manera. Para Cliente Recurrente la división será R1, R2 hasta la R6.
- PD: Probabilidad Default, este campo variará cada mes dependiendo de si el crédito tiene o no un atraso mayor a 60 días (umbral). Cuando haya transcurrido 12 meses (es decir el campo “Maduración” tenga el valor 12) entonces se evaluará los créditos que hayan pasado el umbral. De esta manera

$$PD_{12M} = \frac{\sum \text{Creditos encima umbral}}{\sum \text{Creditos desembolsados ventana 12 meses}}$$

Para efectos de gestión la PD ex post se calcula en una ventana de 12 meses transcurridos, aunque la maduración podría ser en un número mayor de meses como 18.

Figura 10

Comportamiento ejemplo de un crédito con respecto al umbral



En la figura 10 podemos observar el ejemplo de comportamiento de un crédito pueda pasar el umbral y al siguiente mes estar por debajo, demostrando una variabilidad en el tiempo; y, finalmente el crédito al llegar a la maduración 12 (12M) terminó estando por encima del umbral y será considerado en el numeral de la ecuación de PD_M .

Es importante mencionar que la PD_M será un valor diferente para cada agrupación filtro, por ejemplo, la PD_M de la agrupación dada por el campo Segmento con el valor “Cliente Recurrente” en su perfil “R1” será diferente a la agrupación filtro dado por el mismo segmento, pero en el perfil “R2”. De esta manera los PD_M de los créditos con perfil “R1” serán diferentes a los PD_M de los créditos con perfil “R2”

C. Determinación de Variables para el Modelo.

En la etapa de determinación de variables para el entrenamiento del modelo se optó por considerar variables a los campos del flujo de información Ex Ante sumado a los campos en Ex Post del proceso de otorgamiento. De esta manera se considerará 32 variables y, además se considerará tres campos calculados dado que la variable objetivo es la PD. En total los campos considerados serán 35.

Tabla 6

Variables para el entrenamiento

Variable de entrada	Tipo Dato Campo
Estado Civil	Categorico
Ingreso - Ventas	Numérico
Oficio	Categorico
Ubigeo	Numérico
Edad	Numérico
Sexo	Categorico
Departamento	Categorico
Provincia	Categorico
Distrito	Categorico
Nivel Educación	Categorico
Antigüedad Laboral	Numérico
Antigüedad Domiciliaria	Numérico
Tipo Vivienda	Categorico
Situación Laboral	Categorico
Actividad Económica	Categorico

Variable de entrada	Tipo Dato Campo
Numero Entidades	Numérico
Calificación RCC	Numérico
Nombre Producto	Categorico
Línea Producto	Categorico
Código Producto	Numérico
Sub Producto	Numérico
Plazo	Numérico
Código Agencia	Numérico
Tasa Interés	Numérico
Código Campaña	Numérico
Región / Zona	Categorico
Estado Contable	Categorico
Número de cuotas pagadas	Numérico
Número de cuotas impagas	Numérico
Monto Saldo	Numérico
Monto Saldo Vencido	Numérico
Días de atraso	Numérico
PD (M)	Numérico
Segmento	Categorico
Perfil	Categorico

D. Discusión sobre la información base

En la investigación se determinó un total de 34 variables independientes y una variable dependiente. Las variables fueron obtenidas de la revisión del flujo de información en el proceso de otorgamiento de crédito que es el Ex Ante o antes de la operación de desembolso, y el flujo de información Ex Post, donde se adhieren variables con condiciones post desembolso. Estas variables son significativas dado que a partir de algunas se genera variables que parten de campos calculados. En el ámbito nacional podemos comparar con las variables empleadas por Aceituno (2019) quien menciona que las variables que determino tienen validez por su comportamiento en el aspecto financiero.

También resaltamos las variables empleadas en la investigación están sólidamente arraigadas al sector financiero dado que provienen de datos reales de una entidad financiera. A pesar de ello en concordancia con la literatura encontramos en trabajos como de Ampountolas et al. (2021), donde se mencionan el empleo de variables genéricas de información

crediticia, tales como la actividad económica, el saldo capital, días de atraso, estado civil; entre los más resaltantes.

Un aspecto similar podemos encontrar en la investigación de Sheikh et al. (2020) donde encontraremos variables como sexo, estado civil, numero dependientes, monto desembolso, estado contable etc.

Dado este contraste podemos declarar que la investigación sigue la corriente de la literatura y se mantiene dentro del margen. Solo, existe una colaboración adicional al aplicar variables que parten de un cálculo pero que no dejan de ser afines a finanzas.

4.1.2 Resultado de acuerdo al segundo objetivo específico

Para el proceso de entrenamiento de los modelos seleccionados para la investigación se procedió a preparar la información de las variables que se han definido en el punto 4.1. Posterior a ello se realizará el entrenamiento propiamente dicho.

A. Pre procesamiento de datos.

En la tabla 6 del punto 4.1.1 se observa que no todos los campos son numéricos, entonces se debe codificar de tal manera que se pueda manejar en forma numérica que es necesario para el entrenamiento, para ello utilizamos el proceso *One-Hot* especificado en la figura 6 dentro de la metodología. Para ello nos valdremos de la herramienta *Label Encoder* de la librería *sklearn.preprocessing*.

Posterior a ello una vez codificado las variables, se procede a escalar cada uno de ellos, con el fin de que no exista una distancia elevada en valores entre una variable y otra. Para este proceso se utilizó la herramienta *StandardScaler* de la librería *sklearn.preprocessing*.

También se ha escalado a la variable objetivo dado que los modelos no trabajan con valores continuos.

B. Entrenamiento de modelos

Para el entrenamiento de modelos se han utilizado las mismas condiciones y por ende las mismas variables. Los resultados serán evaluados y comparados. Cabe resaltar que la variable objetivo es multiclase al no ser dicotómico, por tanto, la matriz de confusión y el grafico de curva AUC ROC se verán ampliados.

Así mismo del proceso de codificación y escalado a la variable objetivo se han obtenido 32 multiclases. Por tanto, cada clase tendrá una propia métrica de evaluación en *Accuracy*, *Precision*, *Recall*, *F1 Score* y *AUC ROC*. Y, para efecto de comparación de un modelo con otro, se utilizará un valor ponderado en cada métrica por cada modelo.

C. Regresión Logística

Para el entrenamiento de este modelo se utilizó la librería *Scikit Learn*, y la función *LogisticRegression*. Los resultados se muestran en la tabla 7 para cada clase de la variable objetivo.

Tabla 7

Métricas resultantes a nivel multiclase del entrenamiento con RL

Multiclass	Precision	Recall	F1-score	Support
Clase 0	0,96	0,91	0,93	227
Clase 1	0,61	0,53	0,57	947
Clase 2	0,5	0,17	0,25	71
Clase 3	0,99	1	1	3860
Clase 4	0,57	0,58	0,58	1004
Clase 5	0,57	0,65	0,61	908
Clase 6	0,54	0,55	0,54	962
Clase 7	0,71	0,96	0,82	33318
Clase 8	0,66	0,9	0,77	25166
Clase 9	0,86	0,91	0,88	40232
Clase 10	0	0	0	1348
Clase 11	0,41	0,14	0,21	12853
Clase 12	0	0	0	23
Clase 13	0,78	0,82	0,8	100
Clase 14	0	0	0	38
Clase 15	0,7	0,6	0,65	14839
Clase 16	0,73	0,99	0,84	21246
Clase 17	0,53	0,41	0,47	13010

Multiclass	Precision	Recall	F1-score	Support
Clase 18	0,75	0,93	0,83	4832
Clase 19	0,77	0,97	0,86	8841
Clase 20	0,69	0,99	0,81	3019
Clase 21	0,64	0,3	0,4	2171
Clase 22	0,63	0,13	0,22	12371
Clase 23	0,58	0,82	0,68	2758
Clase 24	0,69	0,77	0,73	2108
Clase 25	0,54	0,57	0,55	12257
Clase 26	0,55	0,11	0,19	2828
Clase 27	0,89	0,01	0,02	1050
Clase 28	0,5	0	0,01	4912
Clase 29	0,85	0,28	0,42	4289
Clase 30	0	0	0	23
Clase 31	0,49	0,17	0,26	429
Clase 32	1	1	1	7530

En términos ponderados, se generó los resultados que se muestra en la Tabla 8, donde se tiene el Accuracy (exactitud) en 0,72, la Precision en 0,52, Recall en 0,72 y F1 Score muestra 0,68. Por otro lado, la curva AUC ROC muestra valores más alentadores.

Tabla 8

Métricas ponderadas resultantes del entrenamiento de Regresión Logística

avg	Precision	Recall	F1-score	Accuracy	AUC ROC
Macro	0,60	0,52	0,51	0,72	0,98
Weighted	0,70	0,72	0,68	0,72	0,98

Podemos observar en el Anexo 3 las curvas ROC por cada clase de la variable objetivo para el caso del modelo Regresión Logística.

D. Random Forest

Para el entrenamiento se utilizó la librería *Scikit Learn*, y la función *RandomForestClassifier*. Los resultados se muestran en la tabla 9 para cada clase de la variable objetivo, y en la tabla 10 de forma ponderada.

Tabla 9

Métricas resultantes a nivel multiclase del entrenamiento de Random Forest

Multiclass	Precision	Recall	F1-score	Support
Clase 0	1	0,99	1	227
Clase 1	0,7	0,71	0,71	947
Clase 2	0,88	0,9	0,89	71
Clase 3	1	1	1	3860
Clase 4	0,71	0,73	0,72	1004
Clase 5	0,69	0,69	0,69	908
Clase 6	0,71	0,68	0,7	962
Clase 7	0,93	0,93	0,93	33318
Clase 8	0,9	0,91	0,9	25166
Clase 9	0,97	0,98	0,98	40232
Clase 10	0,89	0,82	0,85	1348
Clase 11	0,79	0,78	0,79	12853
Clase 12	1	1	1	23
Clase 13	0,9	0,99	0,94	100
Clase 14	0,81	0,76	0,78	38
Clase 15	0,93	0,93	0,93	14839
Clase 16	0,92	0,96	0,94	21246
Clase 17	0,8	0,8	0,8	13010
Clase 18	0,92	0,95	0,94	4832
Clase 19	0,98	0,98	0,98	8841
Clase 20	0,88	0,96	0,92	3019
Clase 21	0,88	0,83	0,85	2171
Clase 22	0,75	0,74	0,75	12371
Clase 23	0,9	0,91	0,91	2758
Clase 24	0,93	0,96	0,95	2108
Clase 25	0,79	0,79	0,79	12257
Clase 26	0,95	0,94	0,95	2828
Clase 27	0,8	0,69	0,74	1050
Clase 28	0,81	0,68	0,74	4912
Clase 29	0,89	0,86	0,87	4289
Clase 30	0,92	0,52	0,67	23
Clase 31	0,78	0,57	0,66	429
Clase 32	1	1	1	7530

A su vez se obtiene el resultado de las métricas ponderadas en la tabla 10, donde se observa que la exactitud (Accuracy) está en 0,90, la precisión (Precision) dió en 0,90, la exhaustividad (Recall) en 0,90 y en F1 con el valor de 0,90, La medida de rendimiento dado por la curva ROC

está en 0,99. De esta manera se determina que el modelo de *Random Forest* si es óptimo.

Tabla 10

Métricas ponderadas resultantes del entrenamiento con Random Forest

avg	Precision	Recall	F1-score	Accuracy	AUC ROC
Macro	0,87	0,85	0,86	0,90	0,998
Weighted	0,90	0,90	0,90	0,90	0,996

E. Support Vector Machine

Para el entrenamiento de este modelo también nos valemos de la librería *Scikit Learn* y su función de *SVC*. Una particularidad en este modelo que para efectos de entrenamiento y predicción para variables objetivo multiclase debe aplicarse el tipo *OneVsRestClassifier*, esta opción tomará más tiempo para el entrenamiento. En la tabla 11 mostramos los resultados por cada clase.

Tabla 11

Métricas resultantes a nivel multiclase del entrenamiento con SVM

Multiclass	Precision	Recall	F1-score	Support
Clase 0	1	0,99	1	198
Clase 1	0,51	0,8	0,62	115
Clase 2	0	0	0	2
Clase 3	1	1	1	312
Clase 4	0,56	0,11	0,18	46
Clase 5	0,5	0,17	0,26	99
Clase 6	0,56	0,92	0,7	64
Clase 7	0,65	0,96	0,77	2772
Clase 8	0,59	0,82	0,69	1196
Clase 9	0,89	0,9	0,9	4093
Clase 10	0,56	0,33	0,42	60
Clase 11	0,6	0,01	0,01	1053
Clase 12	1	1	1	4
Clase 13	0	0	0	5
Clase 14	1	0,11	0,2	9
Clase 15	0,8	0,79	0,79	2054
Clase 16	0,73	0,98	0,84	1723
Clase 17	0,55	0,43	0,49	1341
Clase 18	0,69	0,96	0,8	324
Clase 19	0,88	0,99	0,93	633

Multiclass	Precision	Recall	F1-score	Support
Clase 20	0,64	0,98	0,77	171
Clase 21	0,79	0,27	0,41	183
Clase 22	0,7	0,15	0,25	808
Clase 23	0,62	0,48	0,54	66
Clase 24	0,76	0,98	0,86	120
Clase 25	0,52	0,61	0,56	915
Clase 26	0,9	0,23	0,37	113
Clase 27	0	0	0	78
Clase 28	1	0,02	0,03	482
Clase 29	0,82	0,59	0,69	407
Clase 30	0	0	0	1
Clase 31	0	0	0	14
Clase 32	1	1	1	539

De los resultados de este modelo podemos describir la exactitud (Accuracy) da en 0,74, la precisión (Precision) dió en 0,53, la exhaustividad (Recall) en 0,74 y en F1 con el valor de 0,69. La medida de rendimiento dado por la curva ROC está en 0,98. De esta manera se determina que el modelo de SVM tiene un buen rendimiento, pero no alcanza una exactitud aceptable con respecto a sus predecesoras.

Tabla 12

Métricas ponderadas resultantes el entrenamiento con SVM

avg	Precision	Recall	F1-score	Accuracy	AUC ROC
Macro	0,63	0,53	0,52	0,74	0,98
Weighted	0,74	0,74	0,69	0,74	0,98

F. ANN

El modelo de redes neuronales también está contemplado en la librería *Scikyt Learn* con la función *MLPClassifier*, y fue configurado para 50 capas ocultas a un máximo de 50 iteraciones. En la tabla 13 presentamos los resultados por multiclase.

Tabla 13*Métricas resultante a nivel multiclase del entrenamiento con ANN*

Multiclass	Precision	Recall	F1-score	Support
Clase 0	1	1	1	227
Clase 1	0,56	0,8	0,66	947
Clase 2	0,76	0,73	0,75	71
Clase 3	1	1	1	3860
Clase 4	0,58	0,72	0,64	1004
Clase 5	0,63	0,35	0,45	908
Clase 6	0,61	0,46	0,52	962
Clase 7	0,87	0,96	0,91	33318
Clase 8	0,82	0,94	0,88	25166
Clase 9	0,97	0,98	0,97	40232
Clase 10	0,62	0,57	0,59	1348
Clase 11	0,81	0,64	0,72	12853
Clase 12	1	0,96	0,98	23
Clase 13	0,81	1	0,9	100
Clase 14	0,53	0,55	0,54	38
Clase 15	0,94	0,93	0,93	14839
Clase 16	0,88	0,97	0,92	21246
Clase 17	0,77	0,72	0,74	13010
Clase 18	0,8	0,92	0,86	4832
Clase 19	0,98	0,98	0,98	8841
Clase 20	0,74	0,97	0,84	3019
Clase 21	0,74	0,49	0,59	2171
Clase 22	0,69	0,66	0,68	12371
Clase 23	0,77	0,74	0,75	2758
Clase 24	0,83	0,9	0,87	2108
Clase 25	0,8	0,61	0,69	12257
Clase 26	0,94	0,94	0,94	2828
Clase 27	0,6	0,22	0,32	1050
Clase 28	0,83	0,54	0,65	4912
Clase 29	0,94	0,8	0,86	4289
Clase 30	0	0	0	23
Clase 31	0,66	0,25	0,37	429
Clase 32	1	1	1	7530

En el caso de métricas ponderadas para el modelo de ANN se especifican en la tabla 14. Donde se observa que la exactitud (Accuracy) da en 0,87, la precisión (Precision) está en 0,86, la exhaustividad (Recall) en 0,87 y en F1 con el valor de 0,86. La medida de rendimiento dado por la curva ROC está en 0,99. Bajo estos resultados podemos aseverar que el modelo ANN tiene un comportamiento aceptable.

Tabla 14

Métricas ponderadas del entrenamiento con ANN

avg	Precision	Recall	F1-score	Accuracy	AUC ROC
Macro	0,77	0,74	0,74	0,87	0,997
Weighted	0,86	0,87	0,86	0,87	0,996

G. Light Gradient Boost Machine

Este modelo de clasificación fue empleado por Coşer et al. (2019), los resultados del entrenamiento se muestran en la tabla 15, en este caso por cada clase de la variable objetivo.

Tabla 15

Métricas a nivel multiclase resultantes del entrenamiento con LightGBM

Multiclass	Precision	Recall	F1-score	Support
Clase 0	0,97	0,96	0,96	227
Clase 1	0,56	0,8	0,66	947
Clase 2	0,76	0,73	0,75	71
Clase 3	0,96	0,95	0,95	3860
Clase 4	0,58	0,72	0,64	1004
Clase 5	0,63	0,35	0,45	908
Clase 6	0,61	0,46	0,52	962
Clase 7	0,80	0,94	0,89	33318
Clase 8	0,80	0,92	0,86	25166
Clase 9	0,95	0,96	0,95	40232
Clase 10	0,60	0,55	0,57	1348
Clase 11	0,79	0,62	0,70	12853
Clase 12	0,93	0,94	0,96	23
Clase 13	0,79	0,93	0,93	100
Clase 14	0,51	0,53	0,52	38
Clase 15	0,92	0,91	0,91	14839
Clase 16	0,86	0,95	0,90	21246
Clase 17	0,75	0,70	0,72	13010
Clase 18	0,78	0,90	0,84	4832
Clase 19	0,96	0,96	0,96	8841
Clase 20	0,72	0,95	0,82	3019
Clase 21	0,72	0,47	0,57	2171
Clase 22	0,67	0,64	0,66	12371
Clase 23	0,75	0,72	0,73	2758
Clase 24	0,81	0,88	0,85	2108
Clase 25	0,78	0,59	0,67	12257
Clase 26	0,92	0,92	0,92	2828

Multiclass	Precision	Recall	F1-score	Support
Clase 27	0,58	0,20	0,30	1050
Clase 28	0,83	0,54	0,65	4912
Clase 29	0,94	0,8	0,86	4289
Clase 30	0	0	0	23
Clase 31	0,66	0,25	0,37	429
Clase 32	0,99	0,99	0,99	7530

Para los valores de métricas ponderadas para el modelo de *LightGBM* se muestran en la tabla 16. Donde se observa que la exactitud (Accuracy) da en 0,83, la precisión (Precision) muestra 0,84, la exhaustividad (Recall) en 0,85 y en F1 con el valor de 0,84. La medida de rendimiento dado por la curva ROC está en 0,94. Bajo estos resultados podemos aseverar que el modelo *LightGBM* tiene un comportamiento aceptable.

Tabla 16

Métricas ponderadas resultantes del entrenamiento con LightGBM

avg	Precision	Recall	F1-score	Accuracy	AUC ROC
Macro	0,75	0,72	0,73	0,73	0,93
Weighted	0,84	0,85	0,84	0,83	0,94

H. Extreme Gradient Boost

En la investigación de Peter Martey Addo et al. (2018) este modelo tuvo el mejor resultado considerando el contexto de sus variables. En esta investigación los resultados por multiclase de la variable objetivo se muestran en la tabla 17.

Tabla 17

Métricas resultantes a nivel multiclase del entrenamiento con XGBoost

Multiclass	Precision	Recall	F1-score	Support
Clase 0	1	1	1	227
Clase 1	0,73	0,73	0,73	947
Clase 2	0,94	0,89	0,91	71
Clase 3	1	1	1	3860
Clase 4	0,71	0,77	0,74	1004
Clase 5	0,72	0,72	0,72	908
Clase 6	0,73	0,67	0,7	962

Multiclass	Precision	Recall	F1-score	Support
Clase 7	0,92	0,96	0,94	33318
Clase 8	0,89	0,93	0,91	25166
Clase 9	0,98	0,98	0,98	40232
Clase 10	0,90	0,81	0,85	1348
Clase 11	0,91	0,75	0,82	12853
Clase 12	1,00	1,00	1,00	23
Clase 13	0,93	0,99	0,96	100
Clase 14	0,81	0,89	0,85	38
Clase 15	0,94	0,94	0,94	14839
Clase 16	0,90	0,99	0,94	21246
Clase 17	0,80	0,86	0,83	13010
Clase 18	0,92	0,94	0,93	4832
Clase 19	0,99	0,99	0,99	8841
Clase 20	0,88	0,97	0,92	3019
Clase 21	0,86	0,83	0,84	2171
Clase 22	0,81	0,70	0,75	12371
Clase 23	0,91	0,92	0,91	2758
Clase 24	0,95	0,98	0,96	2108
Clase 25	0,79	0,82	0,81	12257
Clase 26	0,95	0,97	0,96	2828
Clase 27	0,79	0,66	0,72	1050
Clase 28	0,93	0,63	0,75	4912
Clase 29	0,94	0,85	0,89	4289
Clase 30	0,94	0,7	0,8	23
Clase 31	0,82	0,57	0,67	429
Clase 32	1	1	1	7530

Para el modelo de *XGBoost* los valores de métricas ponderadas se muestran en la tabla 18. Aquí se observa que la exactitud (Accuracy) da en 0,91, la precisión (Precision) muestra 0,91, la exhaustividad (Recall) en 0,91 y en F1 con el valor de 0,91. La medida de rendimiento dado por la curva ROC está en 0,99. Bajo estos resultados podemos aseverar que el modelo *XGBoost* tiene un comportamiento optimo.

Tabla 18

Métricas ponderadas resultantes del entrenamiento con XGBoost

avg	Precision	Recall	F1-score	Accuracy	AUC ROC
Macro	0,89	0,86	0,87	0,91	0,999
Weighted	0,91	0,91	0,91	0,91	0,998

4.1.3 Análisis comparativo de modelos de *Machine Learning*

Culminada la etapa de entrenamiento y con los resultados por cada modelo de *Machine Learning*, realizamos la comparativa en la Tabla 19, donde se observa que, con respecto al rendimiento (*AUC ROC*), todos los modelos presentan un comportamiento aceptable y hasta optimo, por tanto, nos guiaremos por las otras métricas de evaluación. En cuanto a exactitud (*Accuracy*) el modelo *XGBoost* presenta una mejor puntuación seguido de *Random Forest*.

Tabla 19


Comparativa de métricas resultantes por modelo

Modelo de <i>Machine Learning</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-score</i>	<i>Accuracy</i>	<i>AUC ROC</i>
<i>Regresion Logistica(RL)</i>	0,70	0,72	0,68	0,72	0,980
<i>Random Forest (RF)</i>	0,90	0,90	0,90	0,90	0,996
<i>Support Vector Machines (SVM)</i>	0,74	0,74	0,69	0,74	0,977
<i>Artificial Neural Network (ANN)</i>	0,86	0,87	0,86	0,87	0,996
<i>Light Gradient Boost Machine (LGBM)</i>	0,84	0,85	0,84	0,83	0,937
<i>Extreme Gradiente Boost (XGB)</i>	0,91	0,91	0,91	0,91	0,998

Bajo la evaluación de la métrica de precisión (*Precision*), los modelos de *XGB* y *RF* presentan los mejores valores, esto se debe a que *XGB* se enfoca a predicciones correctas y *RF* se enfoca a casos positivos. Y en global sobre los modelos evaluados, se observa que *XGB* y *RF* muestran las mejores puntuaciones en las demás métricas como Exhaustividad (*Recall*) y *F1*.

Figura 11

Comparación de métricas de los modelos de Machine Learning



Para identificar el modelo con mayor asertividad para la identificación de la probabilidad default de un crédito post impacto COVID-19. Contrastamos los resultados del entrenamiento de cada modelo de *Machine Learning*. Estos resultados fueron medidos por métricas expuestas en los puntos 4.1.2 y 4.1.3.

De la comparativa podemos observar que en cuanto rendimiento medido por la métrica *AUC ROC* todos los modelos muestran valores óptimos, indicando este comportamiento que la predicción con la tasa de verdaderos positivos en cada modelo se muestra por encima de la línea de no discriminación. Como este valor es poco variable de modelo a modelo no nos permite definir abiertamente un modelo que identifique la probabilidad default. Los graficos de las curvas ROC los apreciamos en los Anexos 3,5,7,9,11.

Para encontrar el modelo con mayor asertividad nos valdremos de la métrica de exactitud (*Accuracy*), entonces el modelo con el mayor puntaje es *XGBoost* con 0,91. Sin embargo, no podemos descartar el siguiente modelo que es *Random Forest* que tuvo un valor de exactitud de 0,90, ambos con resultados muy cercanos.

La elección de la métrica *Accuracy* para definir el mejor modelo que identifique la probabilidad default; está respaldada por definición realizada por otros autores como Florez-Lopez y Ramon-Jeronimo (2014), Patel et al. (2020) y Addo et al. (2018).

4.2 Discusión

Para identificar el modelo más exacto, se seleccionaron los algoritmos de *Machine Learning* más destacados para la predicción de la probabilidad default, conforme con la revisión de la literatura presentada en los antecedentes de la investigación, tal como se observa en la Tabla 1. Con autores como Addo et al. (2018), Patel et al. (2020).

Un contraste impórtate identificado con relación a los dataset empleados en los antecedentes, es que la información de la presente investigación es abstraída de una entidad financiera del ámbito nacional local, donde cada variable contiene datos auténticos. Que es superlativo sobre la información que puede ser tomada de buros de set de datos para efectos de entrenamiento como Kaggle u otros. Esta aseveración puede ser corroborada con la presentación de abstracción de datos a variables mediante la revisión del flujo de información en el proceso de otorgamiento de créditos de un estado Ex ante a un estado Ex Post.

De similar aplicación por los autores Ampountolas et al. (2021), Sheikh et al. (2020) y Patel et al. (2020) se utilizan las métricas de *Accuracy*, *Precision*, *Recall* y *F1-Score* los cuales innegablemente dieron resultados que permiten medir el comportamiento de los modelos seleccionados. La interpretación de los resultados podría verse sesgada dado que la variable objetivo es multiclase, sin embargo, al tomar los resultados de las métricas ponderadas por el peso muestral entonces se balancea los valores para un contraste optimo.

Optamos por emplear la métrica *Accuracy* para definir el modelo más adecuado de acuerdo al puntaje mostrado, respaldado en la optación de los trabajos de Florez-Lopez y Ramon-Jeronimo (2014), Patel et al. (2020) y Addo et al. (2018). Dado que esta métrica permite medir de manera global el comportamiento del modelo, considerando además que las variables tienen clases balanceadas.

4.2.1 Prueba de Hipótesis

Para efectos de la prueba de hipótesis con respecto al modelo predictivo de identificación de probabilidad default de un crédito post impacto COVID-19 en el sector financiero peruano mediante técnicas de *Machine Learning*, se ha empleado la prueba de hipótesis denominada prueba t-student, donde se asigna el μ_0 el promedio del resultado de las métricas por cada clase, del modelo de Random Forest, dado que la hipótesis es que este modelo es el de mayor asertividad para la identificación de la probabilidad default de un crédito post impacto COVID-19.

A.1 Con respecto al modelo Regresión Logística

H_0 : La técnica Regresión Logística permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.

H_1 : El modelo Random Forest permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.

$$\mu_a < \mu_b$$

$$\mu_a > \mu_b$$

Tabla 20

Prueba estadística de hipótesis para Regresion Logistica

α	0,01
Tc	6,686456297
Tt	2,654854337
P	6,58296E-09
Decisión	
Tc > Tt	VERDADERO
P < α	VERDADERO

Donde α es el nivel de significancia que está al 99 % de confianza.

- Si Tc > Tt, Se rechaza H_0 y se acepta H_1
- Si P < α , Se rechaza H_0 y se acepta H_1

Se observa que en la Tabla 20 el valor de $T_c = 6,686$ y el valor de $T_t = 2,654$, por tanto, T_c es mayor a T_t y se rechaza la H_0 y se acepta la H_1 , lo que significa que el modelo Regresión Logística no es el modelo que presenta mayor precisión para la identificación de la probabilidad default.

A.2 Con respecto al modelo Support Vector Machines

H_0 : El modelo de *Support Vector Machines* permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.

H_1 : El modelo *Random Forest* permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.

$$\mu_a < \mu_b$$

$$\mu_a > \mu_b$$

Tabla 21

Prueba estadística de hipótesis para Support Vector Machines

α	0,01
T_c	5,917208747
T_t	2,654854337
P	1,40323E-07
Decisión	
$T_c > T_t$	VERDADERO
$P < \alpha$	VERDADERO

Donde α es el nivel de significancia que está al 99 % de confianza.

- Si $T_c > T_t$, Se rechaza H_0 y se acepta H_1
- Si $P < \alpha$, Se rechaza H_0 y se acepta H_1

Se observa que en la Tabla 21 el valor de $T_c = 5,917$ y el valor de $T_t = 2,654$, por tanto, T_c es mayor a T_t y se rechaza la H_0 y se acepta la H_1 , lo que significa que el modelo Support Vector Machines no es el modelo que presenta mayor precisión para la identificación de la probabilidad default.

A.3 Con respecto al modelo Artificial Neural Networks

H_0 : El modelo de *Artificial Neural Networks* permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.

H_1 : El modelo *Random Forest* permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.

$$\mu_a < \mu_b$$

$$\mu_a > \mu_b$$

Tabla 22

Prueba estadística de hipótesis para Artificial Neural Networks

α	0,01
Tc	2,707091219
Tt	2,654854337
P	0,008693271
Decisión	
Tc > Tt	VERDADERO
P < α	VERDADERO

Donde α es el nivel de significancia que está al 99 % de confianza.

- Si Tc > Tt, Se rechaza H_0 y se acepta H_1
- Si P < α , Se rechaza H_0 y se acepta H_1

Se observa que en la Tabla 22 el valor de Tc = 2,707 y el valor de Tt = 2,654, por tanto, Tc es mayor a Tt y se rechaza la H_0 y se acepta la H_1 , lo que significa que el modelo *Artificial Neural Networks* no es el modelo que presenta mayor precisión para la identificación de la probabilidad default.

A.4 Con respecto al modelo Light Gradient Boost Machines

H_0 : El modelo de *Light Gradient BoostMachines* permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.

H_1 : La técnica *Random Forest* permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.

$$\mu_a < \mu_b$$

$$\mu_a > \mu_b$$

Tabla 23

Prueba estadística de hipótesis para Light Gradient Boost Machines

α	0,01
Tc	3,944508696
Tt	2,654854337
P	0,000201063
Decisión	
Tc > Tt	VERDADERO
P < α	VERDADERO

Donde α es el nivel de significancia que está al 99 % de confianza.

- Si Tc > Tt, Se rechaza H_0 y se acepta H_1
- Si P < α , Se rechaza H_0 y se acepta H_1

Se observa que en la Tabla 23 el valor de Tc = 3,944 y el valor de Tt = 2,654, por tanto, Tc es mayor a Tt y se rechaza la H_0 y se acepta la H_1 , lo que significa que el modelo *Light Gradient Boost Machines* no es el modelo que presenta mayor precisión para la identificación de la probabilidad default.

A.5 Con respecto al modelo Extreme Gradient Boost

H_0 : El modelo de *Extreme Gradient Boost* permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.

H_1 : El modelo *Random Forest* permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID-19.

$$\mu_a < \mu_b$$

$$\mu_a > \mu_b$$

Tabla 24

Prueba estadística de hipótesis para Extreme Gradient Boost

α	0,01
Tc	-0,75131799
Tt	2,654854337
P	0,455215211
Decisión	
$Tc > Tt$	FALSO
$P < \alpha$	FALSO

Donde α es el nivel de significancia que está al 99 % de confianza.

- Si $Tc > Tt$, Se rechaza H_0 y se acepta H_1
- Si $P < \alpha$, Se rechaza H_0 y se acepta H_1

Se observa que en la Tabla 24 el valor absoluto de $Tc = 0,751$ y el valor de $Tt = 2,654$, por tanto, Tc es menor a Tt y se acepta la H_0 y se rechaza la H_1 , lo que significa que el modelo Extreme Gradient Boost es el modelo que presenta mayor precisión para la identificación de la probabilidad default desplazando al modelo Random Forest.

CONCLUSIONES

- Se determinó al modelo de *Machine Learning* con mayor exactitud para la identificación de la probabilidad default de un crédito post impacto COVID-19. Que es el modelo Extreme Gradiente Boost (*XGBoost*), que muestra un mejor *Accuracy* de 0,91 respecto a los demás modelos seleccionados Regresión Logística, *Random Forest*, *Support Vector Machines*, *Artificial Neural Network* y *Light Gradient Boost Machines*. La aplicación del proceso mostrado en la presente investigación permitirá identificar la probabilidad default en una ventana de 12 meses con mayor rapidez y mayor frecuencia según la necesidad de aplicarlo.
- Se construyó un dataset para entrenamiento de modelos de *Machine Learning* siguiendo el modelo propuesto en la investigación, el cual consiste en la revisión del flujo de información que se obtiene en el estado Ex Ante del crédito que es antes de la operación de desembolso y se confirma en el estado Ex Post del crédito. Este proceso permitió alimentar un dataset de 35 variables con información de cliente (persona) y con información de condiciones de crédito que son inherentes de la operación de desembolso. Sumado a ello se complementa las variables con campos calculados que son imperativos en una entidad financiera para temas de gestión.
- Se ha medido la asertividad de cada modelo para la identificación de la probabilidad default de un crédito post impacto COVID-19, utilizando métricas como *Accuracy*, *Precision*, *Recall*, *F1 Score* y *AUC ROC*. Optando que la métrica *Accuracy* definiera al modelo con mayor asertividad que es Extreme Gradient Boost con 0,91. Y se detalla que los modelos Regresión Logística, *Random Forest*, *Support Vector Machines*, *Artificial Neural Network* y *Light Gradient Boost* muestran valores de *Accuracy* de 0,72, 0,90, 0,69, 0,86 y 0,83 respectivamente.

RECOMENDACIONES

- Se recomienda aplicar el proceso empleado en la presente investigación para determinar el modelo con mayor exactitud en la predicción de la identificación de la probabilidad default de un crédito post impacto COVID-19 en entidades del sector financiero consumo retail del ámbito nacional.
- Se recomienda la parte pertinente de la organización de una entidad financiera o quien haga las veces de revisión de probabilidad default, haga el uso del modelo con mayor exactitud para la predicción de la identificación de la probabilidad default que es *XGBoost*.
- Se recomienda que en futuras investigaciones los entrenamientos consideren un data set con información de diferentes rubros en cuanto al sector económico y o productos que son propios de cada entidad financiera. De tal manera que enriquecerá el conocimiento y ampliará la atmosfera de investigaciones referentes al tema financiero y crediticio.

BIBLIOGRAFÍA

- Aceituno, M. (2019). *Modelo Predictivo de Análisis de Riesgo Crediticio usando Machine Learning en una entidad del sector microfinanciero*. <http://tesis.unap.edu.pe/handle/20.500.14082/6210>
- Addo, P. M., Guegan, D., y Hassani, B. (2018). Credit risk analysis using machine and deep learning models. *Risks*, 6(2), 1-20. <https://doi.org/10.3390/risks6020038>
- Altman, E. I., Sieradzki, R., y Thlon, M. (2022). Assessing Corporate Credit Risk Transitions and Bankruptcy Prediction on SMEs as a Result of the COVID-19 Pandemic. *SSRN Electronic Journal*. <https://doi.org/10.2139/ssrn.4048333>
- Ampountolas, A., Nyarko Nde, T., Date, P., y Constantinescu, C. (2021). A Machine Learning Approach for Micro-Credit Scoring. *Risks*, 9(3), 50. <https://doi.org/10.3390/risks9030050>
- Arthur L. Samuel. (1959). *Some Studies in Machine Learning Using the Game of Checkers*. <https://doi.org/10.1147/rd.33.0210>
- AWS. (2023). *¿Qué es la regresión logística?* <https://aws.amazon.com/es/what-is/logistic-regression/>
- Barua, S., Gavandi, D., Sangle, P., Shinde, L., y Ramteke, J. (2021). Swindle: Predicting the Probability of Loan Defaults using CatBoost Algorithm. *Proceedings - 5th International Conference on Computing Methodologies and Communication, ICCMC 2021, Iccmc, 1710-1715*. <https://doi.org/10.1109/ICCMC51019.2021.9418277>
- Bhatt, S., Trivedi, B., Devani, A., y Bhimani, H. (2024). *Understanding the Technology behind Traffic Sign Recognition (TSR) Systems*. <https://www.design-reuse.com/articles/41154/traffic-sign-recognition-tsr-system.html>
- Bizagi. (2019). *Bizagi Modeler*. <https://www.bizagi.com/es/plataforma/modeler>
- Canelo, C., y Tocto, P. (2018). Diseño de un modelo basado en redes neuronales en la nube para determinar el riesgo de crédito en los solicitantes de microcrédito en el mercado financiero de Perú. *Proceedings of the 16th LACCEI International Multi-Conference*

- for Engineering, Education, and Technology: "Innovation in Education and Inclusion", 2018-July.* <https://doi.org/10.18687/LACCEI2018.1.1.504>
- Chawla, N. V., Bowyer, K. W., Hall, L. O., y Kegelmeyer, W. P. (2011). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321-357. <https://doi.org/10.1613/jair.953>
- Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 13-17-August-2016*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Chen, Y.-Q., Zhang, J., y Ng, W. W. Y. (2018). Loan Default Prediction Using Diversified Sensitivity Undersampling. *2018 International Conference on Machine Learning and Cybernetics (ICMLC)*, 240-245. <https://doi.org/10.1109/ICMLC.2018.8526936>
- Chris Albon. (2018). *Machine Learning with Python Cookbook Practical Solutions from Preprocessing to Deep Learning* (M. Yarbrough, Ed.; 1.^a ed.). O'Reilly. <https://oreilly.com/catalog/errata.csp?isbn=9781491989388>
- Coenen, L., Abdullah, A. K. A., y Guns, T. (2020). Probability of default estimation, with a reject option. *Proceedings - 2020 IEEE 7th International Conference on Data Science and Advanced Analytics, DSAA 2020*, 439-448. <https://doi.org/10.1109/DSAA49011.2020.00058>
- Coşer, A., Maer-Matei, M. M., y Albu, C. (2019). Predictive models for loan default risk assessment. *Economic Computation and Economic Cybernetics Studies and Research*, 53(2), 149-165. <https://doi.org/10.24818/18423264/53.2.19.09>
- Diario Gestión. (2021, mayo 9). *Minsa: segunda ola se ha desacelerado, pero no pueden afirmar que hay un descenso.* <https://bit.ly/31zovh5>. <https://bit.ly/31zovh5>
- Draw.io. (2024). *Draw.io Process Modeler.* <https://app.diagrams.net/>. <https://app.diagrams.net/>
- Escobar Rozas, F. (2017). Protección EX ANTE v. PROTECCIÓN EX POST: la ejecución de colaterales en operaciones de financiamiento. *THEMIS: Revista de Derecho*, 72, 41-57. <https://doi.org/10.18800/themis.201702.003>

- Florez-Lopez, R., y Ramon-Jeronimo, J. M. (2014). Modelling credit risk with scarce default data: On the suitability of cooperative bootstrapped strategies for small low-default portfolios. *Journal of the Operational Research Society*, 65(3), 416-434. <https://doi.org/10.1057/jors.2013.119>
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189-1232. <https://doi.org/10.1214/aos/1013203451>
- Gutiérrez, D. (2020). *INTRODUCCIÓN A LAS REDES NEURALES PARA VISIÓN ARTIFICIAL CON PYTHON Y RASPBERRY PI*. <https://doi.org/10.13140/RG.2.2.20121.34409>
- Hathidara, A., y Pandey, L. (2024). *Implementing An Artificial Quantum Perceptron*. <http://arxiv.org/abs/2412.02083>
- Hernandez Sampieri, R., Fernandez Collado, C., y Baptista, M. (2014). *Metodología de la investigación* (Mc Graw Hill, Ed.; 6.^a ed., Vol. 6). MC Graw Hill.
- Hurwitz, J., y Kirsch, D. (2018). *Introduction to Machine Learning* (C. A. Burchfield, Ed.). John Wiley y Sons, Inc. www.wiley.com/go/custompub
- IMF. (2020). *Estudio del impacto económico COVID-19 en las empresas*. <https://blogs.imf-formacion.com/blog/mba/estudio-del-impacto-economico-covid-19-en-las-empresas/>
- INEI. (2023, noviembre). *Población y vivienda: Magnitud y Crecimiento Poblacional*. <https://www.inei.gob.pe/estadística/indice-tematico/población-y-vivienda/>.
- Kaggle. (2018, agosto). *XGBoost Extreme Gradient Boost*. <https://www.kaggle.com/code/dansbecker/xgboost>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., y Liu, T.-Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *NIPS'17: Proceedings of the 31st International Conference on Neural Information Processing Systems*, 3149-3157. <https://dl.acm.org/doi/proceedings/10.5555/3294996>
- Keynes, J. M. (2017). La teoría “ex ante” de la tasa de interés. En *Revista de Economía Institucional* (Vol. 19, Número 36, pp. 347-353). Universidad Externado de Colombia. <https://doi.org/10.18601/01245996.v19n36.15>

- Krichene, A. (2017). Using a naive Bayesian classifier methodology for loan risk assessment: Evidence from a Tunisian commercial bank. *Journal of Economics, Finance and Administrative Science*, 22(42), 3-24. <https://doi.org/10.1108/JEFAS-02-2017-0039>
- LeCun, Y., Bengio, Y., y Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436-444. <https://doi.org/10.1038/nature14539>
- M. I. Jordan, y Tom. M. Mitchell. (2015). Machine learning: Trends, perspectives, and prospects. *Science*, 349(6245), 253-255. <https://doi.org/10.1126/science.aac4520>
- Martinez Heras, J. (2023, septiembre). *IArtificial.net*. https://github.com/jmartinezheras/2018-MachineLearning-Lectures-ESA/blob/master/iartificial_net/IArtificial_net.pdf. <https://www.iartificial.net>
- Mcculloch, W. S., y Pitts, W. (1943). A LOGICAL CALCULUS OF THE IDEAS IMMANENT IN NERVOUS ACTIVITY. En *BULLETIN OF MATHEMATICAL BIOPHYSICS* (Vol. 5).
- MEF. (2021, noviembre 5). *Mejora sustancial de las expectativas empresariales se refleja en una mayor dinámica de la economía y generación de empleo*. <https://www.gob.pe/institucion/mef/noticias/551922-mef-mejora-sustancial-de-las-expectativas-empresariales-se-refleja-en-una-mayor-dinamica-de-la-economia-y-generacion-de-empleo>. <https://www.gob.pe/institucion/mef/noticias/551922-mef-mejora-sustancial-de-las-expectativas-empresariales-se-refleja-en-una-mayor-dinamica-de-la-economia-y-generacion-de-empleo>
- Milojević, N., y Redzepagic, S. (2021). Prospects of Artificial Intelligence and Machine Learning Application in Banking Risk Management. *Journal of Central Banking Theory and Practice*, 10(3), 41-57. <https://doi.org/10.2478/jcbtp-2021-0023>
- Patel, B., Patil, H., Hembram, J., y Jaswal, S. (2020). Loan default forecasting using data mining. *2020 International Conference for Emerging Technology, INCET 2020*, 7-10. <https://doi.org/10.1109/INCET49848.2020.9154100>
- Petropoulos, A., Stavroulakis, E., Lazaris, P., Siakoulis, V., y Vlachogiannakis, N. (2023). *Is COVID-19 reflected in AnaCredit dataset? A big data - machine learning*

- approach for analysing behavioural patterns using loan level granular information* (Vol. 315). Bank of Greece. <https://doi.org/10.52903/wp2023315>
- Power Data. (2024). *Big Data y aprendizaje automático*. <https://www.powerdata.es/big-data>
- Provenzano, A. R., Trifirò, D., Datteo, A., Giada, L., Jean, N., Riciputi, A., Pera, G. Le, Spadaccino, M., Massaron, L., y Nordio, C. (2020). *Machine Learning approach for Credit Scoring*. <http://arxiv.org/abs/2008.01687>
- Psaltakis, G., Rogdakis, K., Loizos, M., y Kymakis, E. (2024). One-vs-One, One-vs-Rest, and a novel Outcome-Driven One-vs-One binary classifiers enabled by optoelectronic memristors towards overcoming hardware limitations in multiclass classification. *Discover Materials* , 4(1). <https://doi.org/10.1007/s43939-024-00077-7>
- Raschka, S., y Mirjalili, V. (2019). *Aprendizaje automático con Python* (Sònia Llena, Trad.; 2.^a ed., Vol. 2). MARCOMBO. <https://doi.org/10.3390/info11040193>
- Revista Microfinanzas. (2021). *Las microfinancieras: el vehículo para ayudar a las mypes*. www.microfinanzas.com.pe
- SBS. (2006). *Basilea II - Introducción*. https://www.sbs.gob.pe/Portals/0/jer/REGUL_PROYIMP_BASIL_FUNSBS/BasileaII-Introduccion-JPoggi-MLuy.pdf
- SBS. (2021, septiembre). *Informe de Estabilidad del Sistema Financiero*. 21-25. <https://www.sbs.gob.pe/estadisticas-y-publicaciones/publicaciones/-informe-de-estabilidad-del-sistema-financiero>
- Secretaría de Hacienda y Crédito Público. (2015). *Evaluación Ex post de los Programas y Proyectos de Inversión*. <https://www.gob.mx/shcp/documentos/relacion-de-programas-y-proyectos-de-inversion-sujetos-a-evaluacion-ex-post>
- Sheikh, M. A., Goel, A. K., y Kumar, T. (2020). An Approach for Prediction of Loan Approval using Machine Learning Algorithm. *Proceedings of the International Conference on Electronics and Sustainable Communication Systems, ICESC 2020, Icesc*, 490-494. <https://doi.org/10.1109/ICESC48915.2020.9155614>


- Shoumo, S. Z. H., Dhruva, M. I. M., Hossain, S., Ghani, N. H., Arif, H., y Islam, S. (2019). Application of Machine Learning in Credit Risk Assessment: A Prelude to Smart Banking. *IEEE Region 10 Annual International Conference, Proceedings/TENCON, 2019-Octob*, 2023-2028. <https://doi.org/10.1109/TENCON.2019.8929527>
- Xia, Y., He, L., Li, Y., Fu, Y., y Xu, Y. (2021). A dynamic credit scoring model based on survival gradient boosting decision tree approach. *Technological and Economic Development of Economy*, 27(1), 96-119. <https://doi.org/10.3846/tede.2020.13997>
- Yap, B. W., Ong, S. H., y Husain, N. H. M. (2011). Using data mining to improve assessment of credit worthiness via credit scoring models. *Expert Systems with Applications*, 38(10), 13274-13283. <https://doi.org/10.1016/j.eswa.2011.04.147>
- Zeng, J. Y., Lin, J. B., y Tian, W. (2017). A new competing risks model for predicting prepayment and default using data mining. *2017 2nd International Conference on Image, Vision and Computing, ICIVC 2017, 2013*, 985-989. <https://doi.org/10.1109/ICIVC.2017.7984702>
- Zhao, Z., Xu, S., Kang, B. H., Kabir, M. M. J., Liu, Y., y Wasinger, R. (2015). Investigation and improvement of multi-layer perception neural networks for credit scoring. *Expert Systems with Applications*, 42(7), 3508-3516. <https://doi.org/10.1016/j.eswa.2014.12.006>
- Ziemba, P., Becker, J., Becker, A., Radomska-Zalas, A., Pawluk, M., y Wierzba, D. (2021). Credit decision support based on real set of cash loans using integrated machine learning algorithms. *Electronics (Switzerland)*, 10(17), 1-22. <https://doi.org/10.3390/electronics10172099>

ANEXOS


Anexo 1. Matriz de consistencia

Interrogantes específicas	Hipótesis específicas	Objetivos específicos	Variables	Indicadores	Método s	Prueba Estadística
Pregunta General	Hipótesis General	Objetivo General	General			
PG: ¿Cómo desarrollar un modelo de predicción de riesgo crediticio basado en Machine Learning que permita identificar con precisión la probabilidad de default de créditos otorgados en un contexto post-pandemia COVID-19, considerando las particularidades económicas y financieras del periodo?	HG: El modelo de machine learning, Random Forest (RF) permite identificar con mayor precisión la probabilidad default de un crédito post impacto COVID19.	OE: Desarrollar un modelo de predicción de riesgo crediticio, utilizando modelos de Machine Learning, que permita identificar de manera precisa la probabilidad de default de créditos otorgados en un contexto post-pandemia COVID-19, a partir de la construcción y análisis de un conjunto de datos detallado y representativo.	VI: Modelo de Aprendizaje automático con mayor rendimiento. VD: Probabilidad default de un crédito post COVID 19	Data set. Modelo Diseñado.	Comparación de rendimientos.	Cuadro de pruebas. Tiempo de reconocimiento - Data de entrenamiento o 80% del Dataset - Data de predicción 20% del Dataset Método T-estudent.
Preguntas Específicas	Hipótesis Específica	Objetivo Especifico	Específicos	Específicos		
PE 1: ¿Existe un proceso para construir un data set y cuáles son las variables ponderadas para hallar la probabilidad default de la información pública de créditos post COVID-19?	Las técnicas de machine learning SVM, Random Forest permiten identificar con mayor precisión la probabilidad default de un crédito post impacto COVID- 19.	OE 1: Determinar el procedimiento para obtener un dataset e identificar las variables con mayor poder informativo dentro de la información de créditos post impacto COVID-19 calibrado para obtener mayor precisión.	VI: Data set con información de créditos post COVID-19 VD: Algoritmo con mayor rendimiento de acuerdo con la evaluación de accuracy, precisión, F1-score y recall.	Algoritmo con mejor rendimiento.	Matriz de Confusión y Curva ROC	
PE 2: ¿Cuál es el modelo que tiene mayor rendimiento al hallar la probabilidad default de un crédito con información post COVID-19?	Las técnicas de machine learning Logistic Regresion, ANN, LightGBM o XGBOOST permiten identificar con mayor precisión la probabilidad default de un crédito post impacto COVID- 19.	OE 2: Determinar el modelo de Machine Learning con mayor exactitud para predecir la probabilidad default de un crédito post impacto COVID-19.	VI: Información Pública de créditos post COVID-19 VD: Set de datos construido.	Data set Construido.	Data Set	

Anexo 2. Seguimiento de colocaciones




Anexo 3. Curva AUC ROC de Regresión Logística.




[illegible]


Anexo 5. Curva AUC ROC de Random Forest




Anexo 6. Matriz de confusión de Random Forest




Anexo 7. Curva AUC ROC de Support Vector Machines




Anexo 8. Matriz de confusión de Support Vector Machines




Anexo 9. Curva AUC ROC de Artificial Neural Networks




Anexo 10. Matriz de Confusión de Artificial Neural Networks



Anexo 11. Curva AUC ROC de Extreme Gradient Boost



Anexo 12. Matriz de Confusión de Extreme Gradient Boost



Anexo 13. Declaración jurada de autenticidad de tesis



Universidad Nacional del
Altiplano Puno



Vicerrectorado de
Investigación



Repositorio
Institucional

DECLARACIÓN JURADA DE AUTENTICIDAD DE TESIS

Por el presente documento, Yo **MARCO ANTONIO CHUCUYA TIJUTANI** identificado(a) con N° DNI: **70146904** en mi condición de egresado(a) de la:

MAESTRÍA EN INGENIERÍA DE SISTEMAS

con código de matrícula N° 145967, informo que he elaborado la tesis denominada:

IDENTIFICACIÓN DE PROBABILIDAD DE DEFAULT DE CRÉDITOS POST IMPACTO COVID-19 EN EL SECTOR FINANCIERO PERUANO MEDIANTE TÉCNICAS DE MACHINE LEARNING

Es un tema original.

Declaro que el presente trabajo de tesis es elaborado por mi persona y no existe plagio/copia de ninguna naturaleza, en especial de otro documento de investigación (tesis, revista, texto, congreso, o similar) presentado por persona natural o jurídica alguna ante instituciones académicas, profesionales, de investigación o similares, en el país o en el extranjero.

Dejo constancia que las citas de otros autores han sido debidamente identificadas en el trabajo de investigación, por lo que no asumiré como tuyas las opiniones vertidas por terceros, ya sea de fuentes encontradas en medios escritos, digitales o Internet.

Asimismo, ratifico que soy plenamente consciente de todo el contenido de la tesis y asumo la responsabilidad de cualquier error u omisión en el documento, así como de las connotaciones éticas y legales involucradas.

En caso de incumplimiento de esta declaración, me someto a las disposiciones legales vigentes y a las sanciones correspondientes de igual forma me someto a las sanciones establecidas en las Directivas y otras normas internas, así como las que me alcancen del Código Civil y Normas Legales conexas por el incumplimiento del presente compromiso

Puno. 10 de Marzo del 2025.



FIRMA (Obligatorio)



Huella

Anexo 14. Autorización para el depósito repositorio institucional



Universidad Nacional del
Altiplano Puno



Vicerrectorado de
Investigación



Repositorio
Institucional

AUTORIZACIÓN PARA EL DEPÓSITO DE TESIS O TRABAJO DE INVESTIGACIÓN EN EL REPOSITORIO INSTITUCIONAL

Por el presente documento, Yo **MARCO ANTONIO CHUCUYA TIJUTANI** identificado(a) con N° DNI: **70146904**, en mi condición de egresado(a) del Programa de Maestría o Doctorado:

MAESTRÍA EN INGENIERÍA DE SISTEMAS,

informo que he elaborado la tesis denominada:

IDENTIFICACIÓN DE PROBABILIDAD DE DEFAULT DE CRÉDITOS POST IMPACTO COVID-19 EN EL SECTOR FINANCIERO PERUANO MEDIANTE TÉCNICAS DE MACHINE LEARNING

para la obtención de ☒ **Grado.**

Por medio del presente documento, afirmo y garantizo ser el legítimo, único y exclusivo titular de todos los derechos de propiedad intelectual sobre los documentos arriba mencionados, las obras, los contenidos, los productos y/o las creaciones en general (en adelante, los “Contenidos”) que serán incluidos en el repositorio institucional de la Universidad Nacional del Altiplano de Puno.

También, doy seguridad de que los contenidos entregados se encuentran libres de toda contraseña, restricción o medida tecnológica de protección, con la finalidad de permitir que se puedan leer, descargar, reproducir, distribuir, imprimir, buscar y enlazar los textos completos, sin limitación alguna.

Autorizo a la Universidad Nacional del Altiplano de Puno a publicar los Contenidos en el Repositorio Institucional y, en consecuencia, en el Repositorio Nacional Digital de Ciencia, Tecnología e Innovación de Acceso Abierto, sobre la base de lo establecido en la Ley N° 30035, sus normas reglamentarias, modificatorias, sustitutorias y conexas, y de acuerdo con las políticas de acceso abierto que la Universidad aplique en relación con sus Repositorios Institucionales. Autorizo expresamente toda consulta y uso de los Contenidos, por parte de cualquier persona, por el tiempo de duración de los derechos patrimoniales de autor y derechos conexos, a título gratuito y a nivel mundial.

En consecuencia, la Universidad tendrá la posibilidad de divulgar y difundir los Contenidos, de manera total o parcial, sin limitación alguna y sin derecho a pago de contraprestación, remuneración ni regalía alguna a favor mío; en los medios, canales y plataformas que la Universidad y/o el Estado de la República del Perú determinen, a nivel mundial, sin restricción geográfica alguna y de manera indefinida, pudiendo crear y/o extraer los metadatos sobre los Contenidos, e incluir los Contenidos en los índices y buscadores que estimen necesarios para promover su difusión.

Autorizo que los Contenidos sean puestos a disposición del público a través de la siguiente licencia:

Creative Commons Reconocimiento-NoComercial-CompartirIgual 4.0 Internacional. Para ver una copia de esta licencia, visita: <https://creativecommons.org/licenses/by-nc-sa/4.0/>

En señal de conformidad, suscribo el presente documento.

Puno, 10 de Marzo del 2025.



FIRMA (Obligatorio)



Huella